NVIDIA Isaac Sim i Isaac Lab: uczenie robotów, AGILE, Arena i cyfrowe bliźniaki

Raport syntetyczny · wersja 1.0.0 · 12 listopada 2026 r.
Zakres: ekosystem symulacji, uczenia i ewaluacji polityk robotycznych, w tym humanoidów, modele świata i wdrożenia przemysłowe.

Streszczenie

Ekosystem NVIDIA Isaac łączy symulację fizyczną i sensoryczną, wielkoskalowe uczenie polityk oraz ewaluację zachowania robotów w środowiskach wirtualnych. Niniejszy raport scala dwa nakładające się opracowania o Isaac Sim, Isaac Lab, AGILE i bliźniakach cyfrowych. Wyjaśnia role OpenUSD, Isaac Sim i Isaac Lab, następnie omawia uczenie ze wzmocnieniem, imitację, benchmarki Isaac Lab-Arena, generowanie danych syntetycznych oraz przejście *sim-to-real*. Oddziela elementy platformy od projektów dodatkowych i przykładów przemysłowych. Wnioskiem jest konieczność walidacji polityki zarówno w symulacji, jak i na docelowej platformie sprzętowej, z kontrolą opóźnień, bezpieczeństwa i odporności. Raport stanowi przegląd techniczny, nie sprawozdanie z własnego eksperymentu.

1. Architektura ekosystemu NVIDIA Isaac

OpenUSD (Universal Scene Description) jest formatem i strukturą reprezentacji scen 3D, obejmującą hierarchię obiektów, ich właściwości i powiązania między warstwami danych. Może wspierać integrację modeli CAD, geometrii, materiałów i metadanych. Sama zgodność z OpenUSD nie gwarantuje jednak zgodności modeli dynamiki, czujników ani semantyki interakcji.

Isaac Sim jest środowiskiem symulacyjnym wykorzystującym m.in. PhysX, renderowanie RTX, modele czujników i integracje ROS 2. Służy do projektowania scen, symulacji ruchu i kontaktów oraz tworzenia danych syntetycznych. **Isaac Lab** to otwarty framework uczenia robotów, rozwijany w powiązaniu z Isaac Sim i innymi backendami, obsługujący uczenie ze wzmocnieniem (RL), uczenie przez imitację (IL), symulację równoległą oraz zarządzanie zadaniami [1, 2]. Wcześniejsze opracowania opisywały Isaac Lab wyłącznie jako warstwę Isaac Sim; nowsza architektura 3.x umożliwia również wybrane przepływy bez uruchamiania pełnego Isaac Sim [3].

Komponent	Zakres odpowiedzialności	Typowe zastosowanie
OpenUSD	Reprezentacja i kompozycja scen;	Cyfrowe modele zakładów,

Komponent	Zakres odpowiedzialności	Typowe zastosowanie
	wymiana wybranych danych 3D	geometria, metadane
Isaac Sim	Symulacja fizyki, czujników i renderowania; integracje robotyczne	Testy percepcji, generowanie danych, integracja ROS 2
Isaac Lab	Konfiguracja zadań i środowisk, trening i ewaluacja polityk	RL, IL, równoległe eksperymenty, randomizacja domeny
Isaac Lab-Arena	Modułowe tworzenie i wykonywanie benchmarków	Powtarzalna ocena polityk i generalizacji
AGILE / WBC-AGILE	Projekt zewnętrzny na Isaac Lab, ukierunkowany na sterowanie humanoidami	Trening lokomocji i manipulacji całym ciałem
NVIDIA Cosmos	Modele świata i narzędzia generowania/transformacji danych	Wzbogacanie danych i ocena scenariuszy

Równoległe środowiska umożliwiają próbkowanie wielu epizodów na GPU. Dane obserwacji, akcji i nagród przechowuje się zwykle w strukturach tensorowych, ograniczając koszt przesyłania między procesorem i kartą graficzną. Korzyści zależą jednak od złożoności sceny, modeli czujników, liczby kontaktów i ograniczeń pamięci. Integracja z ROS 2 jest realizowana przez odpowiednie mosty i pakiety; nie jest to odpowiednik jednego uniwersalnego protokołu komunikacyjnego.

2. Uczenie polityk i projekt AGILE

AGILE (*A Generic Isaac-Lab based Engine for humanoid loco-manipulation learning*) jest osobnym projektem WBC-AGILE zbudowanym na Isaac Lab, a **nie silnikiem fizycznym Isaac Sim**. Projekt udostępnia przepływ od konfiguracji zadania i treningu po ewaluację i transfer na roboty fizyczne, z przykładami dla platform humanoidalnych, w tym Unitree G1 i Booster T1 [4].

Proces badawczy warto podzielić na pięć kroków:

1. **Kontrola modelu robota.** Zweryfikować geometrię, ograniczenia stawów, masę i bezwładność, punkty kontaktu, jednostki oraz zgodność aktuatorów z robotem docelowym.
2. **Projekt zadania.** Zdefiniować obserwacje, nagrody, zdarzenia kończące epizod, warunki początkowe, ograniczenia bezpieczeństwa i sposób logowania.
3. **Trening i dobór hiperparametrów.** Rejestrować konfigurację, wersje kodu, losowe ziarna, krzywe uczenia, przebiegi wideo i parametry polityki; rozdzielać trening od oceny.
4. **Ewaluacja ilościowa.** Raportować błędy trajektorii, częstość upadków, skuteczność osiągania celu, odporność na zakłócenia i wyniki dla scenariuszy niewidzianych w treningu.
5. **Transfer i wdrożenie.** Przetestować interfejsy akcji i obserwacji, częstotliwości sterowania, opóźnienia, ograniczenia momentu oraz procedury zatrzymania awaryjnego; potwierdzić zgodność wersji runtime.

Nie należy traktować pojedynczej demonstracji humanoida ani wyniku w jednym symulatorze jako wystarczającego dowodu niezawodności polityki. WBC-AGILE dokumentuje również techniki destylacji *teacher–student* i metody oceny, które pomagają odróżnić trening przy obserwacjach uprzywilejowanych od wdrożenia na rzeczywistych sensorach [4].

3. Isaac Lab-Arena i afordancje

Isaac Lab-Arena służy do budowania benchmarków, wykonywania ewaluacji na wielu scenach i identyfikowania warunków, w których polityka zawodzi [5]. Poziom ewaluacji należy odróżniać od poziomu samego treningu. Powtarzalne benchmarki powinny raportować wersje środowiska, rozkłady inicjalizacji, losowe ziarna i metryki, a także informacje o nieudanych epizodach.

Afordancja (*affordance*) jest opisem możliwej interakcji między robotem a obiektem, np. **Openable** (otwieranie), **Pressable** (naciskanie) lub interakcja z pokrętłem. API afordancji umożliwia definiowanie zadania na poziomie funkcji obiektu, bez wiązania całej logiki z konkretną siatką 3D. Przykładowo polecenie otwarcia można zastosować do różnych typów pojemników o kompatybilnym interfejsie [6]. Jednak wspólna afordancja nie usuwa różnic geometrii, sił kontaktu i ograniczeń mechanicznych; ich obsługa pozostaje problemem kontroli i percepcji.

4. Dane syntetyczne i modele świata

NVIDIA Cosmos stanowi rodzinę narzędzi i modeli świata wykorzystywanych do generowania lub modyfikowania danych

reprezentujących sceny dynamiczne. Materiały źródłowe rozróżniały m.in. mechanizmy typu **Transfer**, służące zmianie wybranych cech wizualnych, i **Predict**, związane z przewidywaniem lub generowaniem przyszłych stanów sceny. Takie narzędzia mogą wspierać randomizację domeny, różnicowanie wyglądu i tworzenie zbiorów do treningu modeli percepcji lub modeli vision–language–action (VLA).

Dane syntetyczne nie zastępują automatycznie danych rzeczywistych. Ich wartość zależy od podobieństwa rozkładów oświetlenia, dynamiki, geometrii, zakłóceń i zachowania sensora do warunków wdrożenia. Szczególnie istotna jest ocena *domain gap*: syntetyczne nagrania mogą utrwalać błędy symulatora. Dlatego eksperyment powinien uwzględniać zbiory z rzeczywistych sensorów i przypadki brzegowe, a nie opierać się wyłącznie na liczbie wygenerowanych epizodów.

5. Real-to-sim, sim-to-real i uczenie przez imitację

Real-to-sim obejmuje pozyskiwanie parametrów i trajektorii z obiektu rzeczywistego oraz przygotowanie odpowiedniego modelu wirtualnego. Mogą tu wystąpić niezgodności w geometrii, kalibracji czujników, tarciu, opóźnieniach i charakterystykach aktuatorów. **Sim-to-real** oznacza przeniesienie polityki sterowania wyuczonej lub dostrojonej w symulacji do robota, który działa przy ograniczeniach rzeczywistego sprzętu.

Typowe ryzyka to niedokładne modelowanie kontaktu, błędne limity stawów, niedoszacowane opóźnienia komunikacji, rozbieżne częstotliwości aktualizacji polityki i symulatora oraz niespójność definicji obserwacji. Stosuje się randomizację parametrów symulacji, identyfikację układu, walidację w trybie *hardware-in-the-loop* i bezpieczny, etapowy wzrost autonomii. Dla humanoidów szczególne znaczenie ma interakcja stóp z podłożem, ale nie można zakładać uniwersalnej wartości błędu transferu (np. w centymetrach) bez konkretnego protokołu testowego.

Imitation learning wykorzystuje demonstracje człowieka albo innego sterownika. W teleoperacji konfiguracja *leader–follower* pozwala gromadzić pary obserwacja–akcja. Istotnym problemem jest akumulacja błędów i przesunięcie rozkładu stanów (*covariate shift*) podczas autonomicznego działania. Pomocne mogą być dodatkowe demonstracje, korekty online lub uzupełnianie treningu interakcją z symulatorem. Materiały źródłowe wymieniały tanie ramiona klasy SO-100 jako przykład sprzętu do pozyskiwania demonstracji; konkretny protokół i kompatybilność sprzętowa wymagają osobnej dokumentacji.

6. Cyfrowe bliźniaki przemysłowe

Cyfrowy bliźniak nie jest synonimem estetycznej wizualizacji. Powinien zachowywać odniesienie do obiektu rzeczywistego, reprezentować istotne parametry i umożliwiać aktualizację danych oraz analizę scenariuszy.

OpenUSD i Omniverse mogą stanowić warstwę kompozycji i wizualizacji, lecz odpowiedzialność za wymianę danych produkcyjnych, aktualność modelu i walidację zależy od rozwiązania integracyjnego.

W obu dokumentach źródłowych opisano przykłady **BMW** (planowanie przestrzeni fabrycznych), **Pegatron** (integracja danych CAD i robotów przemysłowych) oraz **SN Twin** (tworzenie modeli z istniejących danych firmowych). Przykłady te pokazują kierunki zastosowań, nie są natomiast dowodem powtarzalnego efektu liczbowego w każdym zakładzie. W szczególności wzmianka o 99,8% skuteczności inspekcji w pierwotnym raporcie nie zawierała niezależnie udokumentowanego zbioru walidacyjnego, więc nie powinna być cytowana jako ogólny parametr dokładności rozwiązania.

7. Proponowany protokół eksperymentalny

Dla porównywalnego badania polityki należy zapisać: (i) wersje Isaac Lab/Isaac Sim i silnika fizycznego, (ii) model i parametry robota, (iii) inicjalizację i liczbę środowisk, (iv) obserwacje, akcje, funkcję nagrody, (v) seeds i liczbę niezależnych treningów, (vi) metryki sukcesu i bezpieczeństwa, (vii) testy na scenach niewidzianych, (viii) stopień różnicy między symulacją a fizyczną platformą, (ix) sposób kontroli awaryjnej oraz (x) dostępność kodu i danych. Dla systemów VLA i generatywnych modeli świata należy osobno badać wrażliwość na błędne obserwacje oraz niepewność predykcji.

Wnioski

Isaac Sim służy przede wszystkim jako środowisko symulacji i generowania danych, Isaac Lab organizuje trening i testowanie polityk, Isaac Lab-Arena dostarcza warstwę benchmarków, a WBC-AGILE ilustruje specjalistyczny przepływ uczenia sterowania humanoidami. OpenUSD integruje reprezentację scen, a Cosmos może wspierać przygotowanie danych syntetycznych. Zastosowanie tych narzędzi w jednej architekturze nie likwiduje jednak potrzeby weryfikacji realnego sprzętu, ryzyka kontaktu, ograniczeń czujników i kontroli poprawności modelu świata.

Bibliografia i dokumentacja techniczna

1. Mittal, M. i in. (2025). *Isaac Lab: A GPU-Accelerated Simulation Framework for Multi-Modal Robot Learning*. NVIDIA Research. https://research.nvidia.com/publication/2025-09_isaac-lab-gpu-accelerated-simulation-framework-multi-modal-robot-learning
2. NVIDIA Developer. *Isaac Lab*. https://developer.nvidia.com/isaac/lab
3. Isaac Lab, repozytorium i informacje o wersjach 3.x. https://github.com/isaac-sim/IsaacLab/releases

4. NVIDIA Isaac / WBC-AGILE. *A Generic Isaac-Lab based Engine for humanoid loco-manipulation learning*. https://github.com/nvidia-isaac/WBC-AGILE
5. NVIDIA Developer. *Isaac Lab-Arena*. https://developer.nvidia.com/isaac/lab-arena
6. Isaac Lab-Arena. *Affordances*. https://isaac-sim.github.io/IsaacLab-Arena/release/0.3.0/pages/concepts/scene/concept_affordances_design.html
7. NVIDIA. *Isaac Sim – ROS 2*. https://docs.isaacsim.omniverse.nvidia.com/latest/ros2_tutorials/index.html

Pochodzenie i zakres weryfikacji

Raport syntetyzuje `Isaac_Lab.docx` i `Isaac Lab i bliźniaki cyfrowe.pdf` z `files/inne/analizy/`, z aktualizacją terminologii na podstawie oficjalnych źródeł. Zawartość tabeli porównawczej pochodzi z materiałów pierwotnych, lecz została skorygowana o rozwój architektury Isaac Lab. Pominięto niesprawdzone ogólne twierdzenia o dokładności AOI i arbitralnej precyzji sterowania; nie są prezentowane jako wynik badań własnych. Historyczne pliki nie są nadpisywane.