Algorytmy i Telediagnostyka Zaburzeń Neurorozwojowych

Klasyfikacja ADHD/ASD przez ML na platformie MedicalBIT

W kontekście badań nad zastosowaniem modeli uczenia maszynowego (ML) do klasyfikacji Zaburzenia Hiperkinetycznego z Deficytem Uwagi (ADHD) i Zaburzeń ze Spektrum Autyzmu (ASD) oraz ogólnie w Psycho-Informatyce, **dane socjo-anamnestyczne** zbierane zdalnie zostały pozyskane za pośrednictwem włoskiej platformy internetowej o nazwie **MedicalBIT** [1, 2].

MedicalBIT: Internetowa Platforma Skriningowa

MedicalBIT (Medea Information and Clinical Assessment On-Line) jest **pierwszym włoskim internetowym narzędziem kompleksowego skriningu** (przesiewowego) dla zaburzeń neurorozwojowych i problemów emocjonalnych i behawioralnych u dzieci i młodzieży [2, 3].

Kluczowe informacje na temat platformy i zbieranych danych:

- **Cel:** Platforma MedicalBIT została zaprojektowana w celu **standaryzowanego gromadzenia, przetwarzania i eksportowania danych** w rutynie klinicznej psychopatologii dziecięcej [3, 4].
- **Źródło danych:** Dane socjo-anamnestyczne (w tym czynniki socjodemograficzne, kliniczne, środowiskowe i rozwojowe) były zbierane **zdalnie** za pomocą kwestionariuszy wypełnianych przez **rodziców** uczestników [1-3, 5].
- **Zastosowanie w badaniach ML:** W ramach badań na grupie 1688 dzieci i młodzieży, modele ML (Random Forest, Decision Tree, Regresja Logistyczna) zostały wykorzystane do analizy tych internetowych danych, aby **klasyfikować pacjentów pod kątem ryzyka ADHD i ASD** [1, 2, 5].
- **Dane wykorzystane do klasyfikacji:** Niezależne zmienne pochodziły z kwestionariusza socjo-anamnestycznego, który zawierał informacje o czynnikach klinicznych, biologicznych, środowiskowych i rozwojowych. Były to dane wypełniane przez rodziców przed wizytą w instytucie [3, 6]. Samodzielne kategorie diagnostyczne (ADHD/ASD) wprowadzał do platformy dopiero **klinik** [7].

Algorytmy i Telediagnostyka Zaburzeń Neurorozwojowych

W kontekście badań nad zastosowaniem modeli Uczenia Maszynowego (ML) i Psycho-Informatyki w diagnostyce zaburzeń neurorozwojowych, źródła wskazują na kilka projektów badawczych. Przedstawiając cele tych badań, skoncentruję się na dwóch głównych pracach, które w sposób wyraźny sformułowały swoje zadania jako dwa kluczowe cele.

1. Cele badań nad procedurami telediagnostycznymi w neuropediatrii (ADHD i objawy ASD)

W badaniu eksplorującym procedury telediagnostyczne w neuropsychiatrii dziecięcej, mającym na celu wsparcie procesu diagnozowania ADHD na podstawie danych zebranych zdalnie (kwestionariusze wypełniane przez rodziców i nauczycieli), badacze postawili sobie następujące dwa główne cele:

1. **Zrozumienie stopnia pokrywania się informacji z wnioskami klinicznymi:** Zbadanie, w jakim zakresie informacje dostarczone przez rodziców i nauczycieli za pośrednictwem kwestionariuszy online pokrywają się z ostatecznymi wnioskami klinicznymi dotyczącymi diagnozy **Zaburzenia Hiperkinetycznego z Deficytem Uwagi (ADHD)** [1, 2].
2. **Określenie roli objawów ASD jako czynnika zakłócającego:** Zbadanie potencjalnej roli objawów **Zaburzeń ze Spektrum Autyzmu (ASD)** jako możliwego czynnika zakłócającego (*confounding factor*) w procesie ustalania nasilenia ADHD [1, 3].

2. Cele badań nad eksploracją danych dla dorosłych ze Spektrum Autyzmu (ASD)

W badaniach skupiających się na wykorzystaniu eksploracji danych (*Data Mining*) do wykrywania ASD u dorosłych, również sformułowano dwa główne zadania [4, 5]:

1. **Propozycja architektury eksploracji danych:** Zaproponowanie architektury eksploracji danych, która łączy **cechy behawioralne i kliniczne z danymi demograficznymi** [4-6].
2. **Usprawnienie i walidacja diagnozy:** Stworzenie szybkiego, akceptowalnego i prostego sposobu **wspierania diagnozy ASD** poprzez przeprowadzenie studium porównawczego w celu określenia skuteczności czterech możliwych klasyfikatorów (LR, SMO, Naïve Bayes i IBK) [5-8].

Porównanie Klasyfikatorów ML w Diagnozie Neurorozwojowej

Szanowni studenci, w kontekście badań nad eksploracją danych i Psycho-Informatyką, szczególnie tych koncentrujących się na automatyzacji diagnozy zaburzeń neurorozwojowych, kluczowym etapem jest porównanie wydajności różnych algorytmów klasyfikacji (klasyfikatorów) [1-4].

W analizie zbiorów danych dotyczących dorosłych ze Spektrum Zaburzeń Autyzmu (ASD), naukowcy porównali skuteczność czterech potencjalnych klasyfikatorów [1, 2, 4]:

1. **Regresja Logistyczna (LR)** (ang. *Logistic Regression*) [1, 2, 4-7].
2. **Sekwencyjna Minimalna Optymalizacja (SMO)** (ang. *Sequential Minimal Optimization*) [1, 2, 4-7].
3. **Naïve Bayes** [1, 2, 5, 6].

4. **Technika Oparta na Instancjach na podstawie k-sąsiadów (IBK)** (ang. *Instance-based technique based on k-neighbors*) [1, 2, 5, 6].

Wszystkie te klasyfikatory zostały zaimplementowane i przetestowane przy użyciu oprogramowania WEKA (Waikato Environment for Knowledge Analysis) [1, 2, 6, 8].

W innym badaniu, koncentrującym się na diagnozowaniu ADHD i ASD na podstawie cyfrowo zebranych danych socjo-anamnestycznych, również zastosowano porównanie modeli, w tym [9, 10]:

1. **Las Losowy (RF)** (ang. *Random Forest*) [9, 10].
2. **Drzewo Decyzyjne (DT)** (ang. *Decision Tree*) [9, 10].
3. **Regresja Logistyczna (LR)** [9, 10].

Ponadto, w badaniach symulujących proces klasyfikacji ADHD, model drzewa decyzyjnego (DT) był porównywany z innymi modelami Uczenia Maszynowego (ML), takimi jak **Las Losowy (RF)** i **Maszyna Wektorów Wspierających (SVM)** (ang. *Support Vector Machine*) [11, 12].

Kluczowe Miary Wydajności Algorytmów Klasyfikacji

Ocena wydajności algorytmów klasyfikacji w Psycho-Informatyce i eksploracji danych jest fundamentalna, ponieważ pozwala określić, na ile rzetelne są predykcje diagnostyczne dokonywane przez modele Uczenia Maszynowego (ML).

Na podstawie źródeł można wyróżnić trzy główne miary oceny działania (wydajności) algorytmów klasyfikacji, często obliczane za pomocą **macierzy pomyłek** (*confusion matrix*):

1. Dokładność Klasyfikacji (Accuracy)

Dokładność klasyfikacji jest najczęściej stosowaną miarą [1, 2], która określa ogólny odsetek poprawnie wykonanych prognoz [3-5].

- **Definicja:** Jest to odsetek poprawnie sklasyfikowanych przypadków w stosunku do całkowitej liczby wszystkich instancji [3, 4].
- **Wzór (Matematycznie):** Dokładność (Accuracy) oblicza się jako sumę *prawdziwie pozytywnych* (TP) i *prawdziwie negatywnych* (TN) predykcji, podzieloną przez całkowitą liczbę instancji (TP + TN + FP + FN) [6].
- **Zastosowanie:** W badaniu dotyczącym ASD, dokładność klasyfikacji SMO wyniosła 99,71%, przewyższając inne klasyfikatory [1, 7]. W badaniach ADHD/ASD modele Random Forest osiągnęły dokładność 84% i 86% [8].

2. Czułość (Sensitivity / Recall)

Czułość jest miarą skupiającą się na poprawnym identyfikowaniu przypadków faktycznie pozytywnych (np. osób chorych) [3, 4].

- **Definicja:** Jest to odsetek poprawnie wykonanych pozytywnych predykcji (np. „ADHD” lub „ASD”) w stosunku do całkowitej liczby przypadków z faktyczną diagnozą (stanem pozytywnym) [5, 9].
- **Wzór (Matematycznie):** Czułość oblicza się jako *prawdziwie pozytywne* (TP) predykcje, podzielone przez sumę *prawdziwie pozytywnych* (TP) i *fałszywie negatywnych* (FN) predykcji [6].
- **Zastosowanie:** Modele RF dla klasyfikacji ADHD osiągnęły czułość 93%, a dla ASD 95% [8, 10]. W badaniach ASD u dorosłych klasyfikator SMO osiągnął czułość 100% [7, 11].

3. Specyficzność (Specificity / Precision)

Specyficzność mierzy zdolność algorytmu do poprawnego identyfikowania przypadków faktycznie negatywnych (np. osób zdrowych, kontrolnych) [3, 4].

- **Definicja:** Jest to odsetek poprawnie wykonanych negatywnych predykcji (np. „nie-ADHD” lub „nie-ASD”) w stosunku do całkowitej liczby przypadków bez faktycznej diagnozy (stanem negatywnym) [4, 5].
- **Wzór (Matematycznie):** Specyficzność oblicza się jako *prawdziwie negatywne* (TN) predykcje, podzielone przez sumę *prawdziwie negatywnych* (TN) i *fałszywie pozytywnych* (FP) predykcji [6].
- **Zastosowanie:** Modele RF dla ADHD i ASD osiągnęły odpowiednio 75% i 77% specyficzności [10]. Klasyfikator SMO w badaniu ASD u dorosłych osiągnął specyficzność 99% [7, 11].

Dodatkowo, w ocenie działania algorytmów stosuje się takie miary jak **Wartość Predykcyjna Pozytywna (PPV)** oraz **Wartość Predykcyjna Negatywna (NPV)** [9].

Krytyka samoopisu: Pamięć, afekt i pożądanie społeczne

Z perspektywy tradycyjnej psychometrii, samoopis (self-report) jest krytykowany jako metoda obarczona poważnymi wadami, które wynikają głównie z subiektywnych zniekształceń percepcji, pamięci i wpływu kontekstu społecznego.

Oto główne powody, dla których samoopis jest obarczony błędem:

1. Zniekształcone przypominanie (Poor Recollection)

Ludzie mają trudności z dokładnym i rzetelnym przywoływaniem informacji na temat swojego zachowania, zwłaszcza w odniesieniu do dłuższych okresów [1].

- **Niedokładne oszacowania:** Uczestnicy często błędnie lub niedokładnie przypominają sobie zmienne będące przedmiotem zainteresowania, zwłaszcza gdy interwały raportowania są zbyt długie [1]. Na przykład, bardzo niewiele osób potrafi dokładnie podać, jak często sprawdzało pocztę e-mail w ciągu ostatnich 10 dni, co jest zmienną istotną przy badaniu uzależnienia od Internetu/urządzeń cyfrowych [1, 2].

- **Wirtualny charakter zachowań:** W przypadku zachowań wirtualnych, takich jak korzystanie z telefonu, kwantyfikacja jest trudniejsza. Pacjenci/uczestnicy badań nie są w stanie dokładnie odpowiedzieć, ile razy dziennie odblokowują telefon (co może wynosić do 200 razy dziennie) [2, 3]. W przeciwieństwie do, na przykład, spożycia alkoholu, gdzie kwantyfikacja jest łatwiejsza choćby ze względu na liczbę pustych butelek, w przypadku interakcji z urządzeniami cyfrowymi brakuje fizycznych „śladów" ułatwiających przypomnienie [2].

2. Wpływ aktualnego stanu psychicznego i subiektywności

Samoocena jest silnie obciążona chwilowym stanem emocjonalnym i percepcją rzeczywistości przez osobę badana [1].

- **Zmieniony stan afektywny:** Raporty dotyczące subiektywnego dobrostanu mają tendencję do odzwierciedlania zmienionego stanu afektywnego w momencie raportowania [1].
- **Percepcja zaburzona chorobą:** Pacjent cierpiący na depresję zazwyczaj oceni swoje samopoczucie, funkcjonowanie społeczne i warunki życia jako gorsze, niż oceniłby to niezależny obserwator lub on sam po wyzdrowieniu [1]. Pacjenci wykorzystują swój chwilowy stan afektywny do oceny, jak szczęśliwi i zadowoleni są ze swojego życia ogólnie [1].
- **Wprowadzenie szumu do danych:** Te czynniki (stan umysłu w momencie raportowania) wprowadzają znaczący szum do rzadko rejestrowanych danych [1].

3. Pożądanie społeczne (Social Desirability)

Na samoocenę wpływa również to, jak bardzo zgłaszane zachowanie jest pożądane społecznie. Ludzie mają tendencję do przedstawiania się w lepszym świetle, zgodnie z oczekiwaniami społecznymi, co dodatkowo zniekształca dane [1].

Podsumowując, tradycyjne metody opierające się na samoopisie generują dane **wadliwe i zniekształcone**, które słabo oddają rzeczywistą sytuację pacjenta [1, 4]. Psycho-Informatyka, koncentrując się na **obiektywnym, pasywnym zbieraniu danych** (np. przez smartfony), ma na celu uniknięcie tych dominujących źródeł błędu [5, 6].

Bariery Czasowe i Finansowe Badań Psychometrycznych

W kontekście omawiania ograniczeń tradycyjnych metod psychometrycznych, które motywują rozwój nowej dziedziny, jaką jest Psycho-Informatyka, kwestia **zbyt grubej ziarnistości czasowej** (coarse temporal granularity) jest kluczowa. Oznacza ona, że dane zbierane są zbyt rzadko, aby uchwycić istotne, dynamiczne wzorce zachowania i emocji [1, 2].

Tradycyjne metody mają zbyt zgrubną ziarnistość czasową z kilku fundamentalnych, głównie praktycznych, powodów:

1. Ograniczenia finansowe i koszty [1, 3]

Przeprowadzanie tradycyjnych badań wymaga zaangażowania wykwalifikowanego personelu, co generuje wysokie koszty:

- **Wysoki koszt wywiadów:** Wywiady kliniczne muszą być prowadzone przez przeszkolonego specjalistę. W zależności od poziomu wyszkolenia i statusu zatrudnienia, **pojedynczy wywiad może szybko kosztować kilkaset euro** [1, 3].
- **Wymaganie częstych wywiadów jest zaporowo drogie** (prohibitively expensive) [1].

2. Duże obciążenie dla uczestnika (Burden on Participant) [1, 3]

Częste zbieranie danych jest niepraktyczne i nadmiernie uciążliwe dla pacjentów:

- **Konieczność dojazdów i spotkań:** Konieczne spotkania narzucają **zbyt duże obciążenie na uczestnika**, zwłaszcza gdy treść wywiadów dotyczy wyłącznie negatywnych aspektów życia, takich jak zaburzenia psychopatologiczne [3].
- **Zużycie czasu:** Wliczając czas podróży, pojedynczy wywiad może pochłonąć **większą część dnia**, co jest obciążeniem, które można narzucać rzadko, szczególnie osobom prowadzącym życie zawodowe [3].
- **Dzienniczki samooceny:** Nawet stosowanie dzienniczków samooceny (self-reports in form of diaries) szybko napotyka limit zaangażowania czasowego, jakiego można oczekiwać od uczestnika [3].

3. Ograniczenia metodologiczne i efekty pamięci [1]

Sama natura testów psychometrycznych uniemożliwia ich częste stosowanie w krótkich odstępach czasu:

• **Efekty pamięci i uczenia się:** Nie jest możliwe wielokrotne przeprowadzanie **identycznego testu psychometrycznego** w ciągu jednego dnia. **Efekty pamięci i uczenia się** ograniczyłyby wiarygodność ocen [1].

• **Brak możliwości ciągłej obserwacji:** Całodobowe „śledzenie" pacjenta (*around-the-clock shadowing*) nie jest ani akceptowalne dla uczestnika, ani opłacalne finansowo [1].

W rezultacie tych ograniczeń, tradycyjnie badacze stosują kwestionariusze w **ustalonych odstępach czasu** (np. tygodniowych, miesięcznych lub rzadziej), polegając na samoocenie uczestników [1]. Taka niska granularność jest niewystarczająca do uchwycenia dynamicznych, drobnoziarnistych wzorców [1].

Subiektywizm i granularność: Krytyka psychometrii klasycznej

W kontekście dyskusji nad **Psycho-Informatyką** i rewolucją Big Data w psychiatrii i psychologii, kluczowe jest głębokie zrozumienie fundamentalnych ograniczeń i wad, które charakteryzują tradycyjne metody psychometryczne. Te metody, opierające się na obserwacjach klinicystów i testach samooceny, pozostawały w dużej mierze niezmienione przez większą część ubiegłego stulecia [1].

Poniżej przedstawiam główne wady tradycyjnej psychometrii, które stały się główną siłą napędową poszukiwania nowych, cyfrowych rozwiązań:

1. Niska jakość danych i obciążenia subiektywne (Bias and Distortion)

Tradycyjne metody zbierania danych generują informacje, które są podatne na błędy, zniekształcenia i stronniczość, co obniża ich wiarygodność [2].

- **Zniekształcone przypominanie (Poor recollection):** Uczestnicy często podają błędne lub niedokładne informacje na temat zmiennych będących przedmiotem zainteresowania, szczególnie gdy interwały czasowe raportowania są długie. Jest to szczególnie problematyczne w przypadku interakcji z urządzeniami cyfrowymi; niewiele osób potrafiłoby dokładnie oszacować, jak często sprawdzało e-mail w ciągu ostatnich 10 dni [2].
- **Wpływ aktualnego stanu psychicznego:** Samoocena dotycząca subiektywnego dobrostanu jest silnie powiązana z chwilowym stanem afektywnym. Pacjent w depresji, na przykład, zazwyczaj oceni swoje samopoczucie, funkcjonowanie społeczne i warunki życiowe jako gorsze, niż widziałby je niezależny obserwator lub on sam po wyzdrowieniu [2].
- **Wpływ pożądania społecznego (Social desirability):** Na samoocenę wpływa również społeczna pożądanie zgłaszanego zachowania. Czynniki te wprowadzają znaczący szum do rzadko rejestrowanych danych [2].
- **Subiektywność oceny eksperta:** Nawet testy psychometryczne oceniane przez klinicystów niosą ryzyko bycia stronniczymi, ponieważ oceny ekspertów nie są całkowicie obiektywne. Lepiej jest określać je mianem ocen „zewnętrznych" niż „obiektywnych" [2].

2. Ograniczona ilość danych i niska granularność czasowa

Tradycyjne metody cechują się małą ilością danych (Quantity) i nie są w stanie uchwycić dynamicznych, drobnoziarnistych wzorców temporalnych (Temporal Granularity) [3, 4].

- **Zbyt gruba granularność czasowa:** Czasowa granularność, z jaką tradycyjne metody zbierają dane (np. kwestionariusze cotygodniowe lub comiesięczne), jest zbyt niska, aby ujawnić drobnoziarniste wzorce [3, 4].
- **Problemy z replikacją testów:** Nie jest możliwe wielokrotne przeprowadzanie identycznego testu psychometrycznego w ciągu jednego dnia ze względu na **efekty pamięci i uczenia się**, które ograniczyłyby wiarygodność wyników [3].
- **Ograniczenia praktyczne i finansowe:**
    - **Koszty:** Wymaganie częstych wywiadów jest **zaporowo drogie**, ponieważ muszą być prowadzone przez przeszkolonego specjalistę, a pojedynczy wywiad może kosztować kilkaset euro [3, 5].

    - **Obciążenie pacjenta:** Częste spotkania stanowią **zbyt duże obciążenie dla uczestnika**, zwłaszcza gdy dotyczą negatywnych aspektów życia (np. zaburzeń psychopatologicznych). Dotyczy to również prowadzenia dzienniczków samooceny [5].
    - **Brak możliwości ciągłej obserwacji:** Całodobowe obserwowanie pacjenta (*around-the-clock shadowing*) nie jest ani akceptowalne dla uczestnika, ani opłacalne finansowo [3].
- **Płytkie skale pomiarowe:** Metody tradycyjne często wykorzystują płytkie skale (np. większość kwestionariuszy dotyczących depresji pozwala na odpowiedzi na skali 0–3), co prowadzi do **szybkich efektów pułapu/podłogi** (*floor effects*) [4]. Ten brak precyzji pomiaru może mieć dramatyczne konsekwencje, ponieważ uniemożliwia wiarygodne ilościowe określenie pozytywnych efektów nowych substancji psychotropowych we wczesnych fazach badań [4].

Podsumowując, tradycyjne metody słabo oddają rzeczywistą sytuację kliniczną pacjenta lub uczestnika badania, ponieważ dane są zbierane zbyt rzadko, brakuje im dynamiki, a ich jakość jest obniżona przez nieobiektywne błędy i subiektywne zniekształcenia [4].

Smartfon jako Lustro Stanu Psychicznego

W obszarze Psycho-Informatyki, czyli zastosowania Big Data w psychologii i psychiatrii [1], interakcja użytkownika ze smartfonem jest traktowana jako niezwykle bogate i intymne źródło informacji, które bezpośrednio odzwierciedla jego stan psychiczny, emocjonalny i behawioralny [2, 3]. Zgodnie z centralną tezą tej metodyki, stan psychiczny użytkownika wpływa na sposób, w jaki wchodzi on w interakcję z urządzeniem, a co za tym idzie, zmiany w tej interakcji odzwierciedlają zmiany w jego stanie psychicznym [4].

Smartfony są idealnym narzędziem do tego typu monitorowania, ponieważ są noszone przez użytkowników całodobowo i służą do szerokiego zakresu komunikacji [2, 5].

Sposób, w jaki interakcja ze smartfonem odzwierciedla stan psychiczny:

1. Wskaźniki Energetyczne i Motywacyjne (Choroby Afektywne)

Monitorowanie aktywności na smartfonie ma na celu wykrycie zmian w **energii, dynamice, anhedonii i wycofaniu społecznym**, które są centralnymi objawami zaburzeń, takich jak depresja [6].

Aspekt Interakcji	Oczekiwane Zachowanie w Depresji (Niska Energia/Anhedonia)	Potencjalna Interpretacja Kliniczna
Użycie aplikacji (App Usage)	**Mniej energii i dynamiki** [6]. Użytkownik rzadziej włącza telefon, spędza mniej czasu w głównym menu [7].	Wskazuje na **wycofanie, spadek energii** i ogólną anhedonię [6].

Makro-ruch (Macro movement)	Rzadsze rejestrowanie pozycji geograficznej za pomocą GPS/Wi-Fi/triangulacji, co sugeruje, że pacjent **rzadziej opuszcza mieszkanie** [8].	Odzwierciedla **wycofanie społeczne** i niski poziom aktywności [6].
Interakcje społeczne	**Mniejsza ilość połączeń/SMS-ów** przychodzących i wychodzących. Zmniejszenie liczby kontaktów, z którymi użytkownik regularnie się komunikuje [9].	Wskazuje na **wycofanie społeczne**, jeden z centralnych symptomów depresji [6, 9].
Wzorce czasowe	Późniejsze pory pierwszego skorzystania z telefonu rano [10].	Może odzwierciedlać **zaburzenia snu** lub późne wstawanie, powiązane z depresją [10].

2. Wskaźniki Behawioralne i Osobliwości (Stres, Zaburzenia)

Interakcja z urządzeniami cyfrowymi może również odzwierciedlać chwilowe stany psychiczne, takie jak stres, zmęczenie lub problemy z regulacją zachowania:

• **Błędy typograficzne:** Użytkownik będący w stanie **stresu lub zmęczenia** może generować więcej błędów typograficznych niż zwykle na komputerze stacjonarnym [4, 11].

• **Wzorce użycia mediów cyfrowych:** Badanie częstotliwości odblokowywania telefonu (nawet do 200 razy dziennie) lub sprawdzania e-maili [10, 12] stanowi jedyny ważny miernik **uzależnienia od Internetu/mediów cyfrowych**, którego pacjenci nie są w stanie dokładnie zaraportować w ankietach (zniekształcone przypominanie) [12].

3. Wskaźniki Osobowościowe i Behawioralne

Obserwowanie interakcji może również dostarczyć wskaźników cech osobowości:

• **Ekstrawersja:** Osoba **ekstrawertyczna** może być łatwo wykryta na podstawie dużej liczby połączeń przychodzących i wychodzących, co wskazuje na dużą aktywną sieć społeczną [3].

• **Introwersja:** Osoba **introwertyczna** może wykazywać dłuższe sesje czytania, na przykład w aplikacji do e-booków [3].

• **Otwartość na nowe doświadczenia:** Osoba **otwarta na nowe doświadczenia** może często instalować i testować nowe aplikacje [3].

Dzięki Psycho-Informatyce i Big Data, psychiatrzy i psycholodzy mogą po raz pierwszy obserwować zachowanie w **drobnoziarnistej granularności czasowej** i na dużą skalę [3, 13, 14], uzyskując dane o wyższej jakości (ponieważ nie są obciążone stronniczymi samoopisami) [13].

Narzędzia Big Data w Psychologii i Psychiatrii

Zagadnienie narzędzi Psycho-Informatyki jest kluczowe dla zrozumienia, w jaki sposób ta nowa dyscyplina, definiowana jako **zastosowanie Big Data w psychologii i psychiatrii** [1], realizuje swoją obietnicę dokonania największej zmiany metodologicznej w tych naukach [2].

Narzędzia Psycho-Informatyki należy rozumieć w szerokim kontekście, obejmującym nie tylko konkretne algorytmy, ale całą architekturę technologiczną – od źródeł danych po zaawansowane platformy analityczne.

1. Architektura Technologiczna i Platformy [2, 3]

Wizja technologiczna Psycho-Informatyki opiera się na transferze technik z informatyki do psychiatrii i psychologii [2]. Składa się ona z trzech głównych komponentów [2]:

1. **Liczne źródła danych i sensory** (np. urządzenia mobilne) [2].
2. **Centralna przechowalnia danych** (*Data Store*) [2], której zadaniem jest gromadzenie, czyszczenie, transformacja i zarządzanie masowymi zbiorami informacji [3].
3. **Platforma analityczna** (Analytics Platform) [2], wykorzystująca techniki eksploracji danych (*data mining*) i uczenia maszynowego (*machine learning*) [2].

2. Narzędzia Zbierania Danych (Źródła Informacji)

Kluczowym elementem jest zdolność do zbierania danych o najwyższej jakości i precyzyjnej granularności czasowej, najlepiej bez aktywnej interakcji użytkownika [4, 5].

Kategoria	Przykłady i Funkcje	Cytowania
Smartfony (najważniejsze źródło)	Stanowią intymne i najbogatsze źródło danych behawioralnych [6]. Umożliwiają rejestrację interakcji użytkownika z aplikacjami (*app usage*), wzorców komunikacji (połączenia telefoniczne, SMS) oraz **makro-ruchu** (dzięki GPS i triangulacji wież komórkowych) [6-8].	[6-8]
Sensory i urządzenia noszone (*Wearable Sensors*)	Małe i niedrogie czujniki (np. akcelerometry, inteligentne zegarki i okulary) [9, 10] zbierające dane o ruchu [6, 10].	[6, 9, 10]
Urządzenia Ubiquitous Computing	Wszelkie maszyny umożliwiające interakcję, takie jak komputery stacjonarne (rejestrujące błędy typograficzne, mogące wskazywać na stres) [11], ekspresy do kawy, samochody czy lodówki [11].	[11]
Usługi i aplikacje internetowe	Sieci społecznościowe, platformy zakupowe, gry online. Dostarczają danych o interakcjach społecznych, zachowaniach zakupowych i wzorcach gier, które mogą korelować z cechami osobowości [9].	[9]

Platformy do zdalnej administracji	Platformy internetowe, takie jak *MedicalBIT*, służące do zdalnego zbierania kwestionariuszy i danych socjo-anamnestycznych od opiekunów [12, 13].	[12, 13]

3. Narzędzia Analityczne i Metody Sztucznej Inteligencji

Analityka w Psycho-Informatyce polega na zastosowaniu zaawansowanych algorytmów do identyfikacji wzorców, trendów i klasyfikacji [14].

Technika Analityczna	Rola i Zastosowanie	Cytowania
Uczenie Maszynowe (Machine Learning, ML)	Metoda mająca na celu "nauczenie się" właściwości na podstawie zbioru danych treningowych w celu automatycznej klasyfikacji nowych przypadków [14]. Stosowana jest do wspierania diagnozy [15].	[14, 15]
Modele Klasyfikacyjne (ML)	Służą do przewidywania przynależności do określonej klasy diagnostycznej (np. ADHD/non-ADHD lub ASD/non-ASD) [14, 16, 17]. Do najczęściej stosowanych modeli należą: **Random Forest (RF)** (często osiąga najwyższą dokładność) [18, 19], **Decision Tree (DT)** (łatwiejsze w interpretacji) [18, 19], **Sequential Minimal Optimization (SMO)** (wykazał najwyższą dokładność w detekcji ASD) [20, 21], **Logistic Regression (LR)** [18], oraz **Support Vector Machines (SVM)** [22].	[14, 18-22]
Eksploracja Danych (Data Mining)	Służy do wykrywania nieznanych wcześniej trendów i wzorców w masowych zbiorach danych [14].	[14]
Analiza SHAP (*Shapley additive explanations*)	Używana do zwiększenia interpretowalności modeli "czarnej skrzynki" (jak Random Forest), oceniając wpływ poszczególnych zmiennych na wynik klasyfikacji [23, 24].	[23, 24]
Statystyka (Tradycyjna i Zaawansowana)	Używana do analizowania danych, od prostego zliczania po zaawansowane techniki wykrywania wzorców czasowych [3, 25].	[3, 25]

4. Oprogramowanie i Środowiska Pracy

Do realizacji procesów Psycho-Informatyki wykorzystywane są specjalistyczne pakiety i środowiska programistyczne:

- **WEKA** (*Waikato Environment for Knowledge Analysis*): Popularne narzędzie typu *open-source* do eksploracji danych i uczenia maszynowego [26], stosowane do przetwarzania wstępnego i klasyfikacji zbiorów danych [27].
- **Aplikacje mobilne:** Specjalnie zaprojektowane aplikacje (jak np. "ASD Tests" lub aplikacje do monitorowania depresji) służące do zbierania danych behawioralnych bezpośrednio na urządzeniu [28, 29].

Płeć jako kluczowy predyktor ADHD i ASD

koncentrując się na modelach uczenia maszynowego (ML) wykorzystujących cyfrowo zbierane dane socjo-anamnestyczne do klasyfikacji zaburzeń neurorozwojowych (takich jak ADHD i ASD), kluczowe jest zidentyfikowanie, który czynnik miał największą moc predykcyjną.

Najsilniejszym predyktorem w klasyfikacji zarówno **ADHD**, jak i **ASD** okazała się zmienna związana z **płcią (Sex)** [1].

Poniżej przedstawiam szczegóły, w jaki sposób ten czynnik oraz inne istotne predyktory zostały zidentyfikowane przez modele:

1. Klasyfikacja ADHD

W modelach leśnych losowych (RF), które wykazały najwyższą dokładność (84%) [2, 3]:

- **Płeć (Sex):** została zidentyfikowana jako **najsilniejszy predyktor**, wykazując **najwyższą zdolność dyskryminacyjną** wśród analizowanych przypadków [1].
- Modele regresji logistycznej (LR) również wskazały płeć (współczynnik szans, OR = 2,14) jako istotny predyktor statystyczny dla ADHD [4]. Jest to zgodne z faktem, że u mężczyzn częściej diagnozuje się ADHD niż u kobiet [1, 5].

2. Klasyfikacja ASD

Podobnie jak w przypadku ADHD, model RF (dokładność 86%) oraz inne modele również podkreślały znaczenie płci:

- **Płeć (Sex):** była jednym z **najważniejszych predyktorów** [1, 6].
- Modele LR wykazały jeszcze wyższą wartość współczynnika szans (OR = 3,88) dla płci w klasyfikacji ASD, co jest zgodne z faktem, że płeć męska jest częściej diagnozowana z ASD [1, 5, 7].

3. Inne istotne czynniki predykcyjne

Modele RF, charakteryzujące się wyższą dokładnością, zidentyfikowały również inne czynniki, które konsekwentnie plasowały się wysoko w rankingu ważności (analiza SHAP) dla obu diagnoz, zaraz po płci:

- **Ryzyko przed- i okołoporodowe (Pre- and perinatal risk)** oraz **Obawy rozwojowe (Developmental concerns)** okazały się wpływowymi predyktorami zarówno dla ADHD, jak i ASD [1, 6].
- **Dodatni wywiad rodzinny (Positive familiarity)**, uwzględniając znaczny stopień dziedziczności obu schorzeń neurorozwojowych, również stanowił istotny predyktor dla klasyfikacji [1, 6].

Należy zaznaczyć, że chociaż **płeć** była najsilniejszym predyktorem w modelach RF, które dają wyższą dokładność klasyfikacji, w modelach drzew decyzyjnych (DT) dla ADHD, najbardziej dyskryminującą informacją była **ocena nasilenia podstawowych objawów ADHD** (Parent- and teacher-reported ADHD core symptom severity) [8, 9]. Jednakże, w badaniu analizującym dane socjo-anamnestyczne, to płeć była czynnikiem o najwyższej mocy dyskryminacyjnej w przypadku klasyfikacji ryzyka ADHD/ASD [1].

Wsparcie Diagnozy ADHD: Cele Modeli Uczenia Maszynowego

Główny cel badań modeli Uczenia Maszynowego (ML – *Machine Learning*) w kontekście diagnozowania i badania **Zaburzenia Hiperkinetycznego z Deficytem Uwagi (ADHD)** jest wielopłaszczyznowy, koncentrując się na **usprawnieniu i automatyzacji procesu diagnostycznego** oraz **identyfikacji predyktorów** tej neurozwojowej przypadłości.

Poniżej przedstawiam główne cele, które są realizowane w badaniach z wykorzystaniem modeli ML dla ADHD:

1. Wspieranie i automatyzacja procesu diagnostycznego

Głównym celem jest wykorzystanie modeli ML do stworzenia **narzędzi wspomagających klinicystów** w diagnozowaniu ADHD, szczególnie w kontekście cyfryzacji i telemedycyny [1-5].

- **Klasyfikacja i identyfikacja ryzyka:** Modele ML (takie jak Drzewa Decyzyjne – DT, Lasy Losowe – RF czy Regresja Logistyczna – LR) są tworzone w celu **klasyfikowania** dzieci i młodzieży jako przypadków ADHD/nie-ADHD [2, 6-8]. Ma to na celu **szybkie uzyskanie automatycznego wyniku** wskazującego na ryzyko diagnostyczne [1, 9].
- **Wydajność i skrócenie czasu:** Automatyzacja diagnozy ryzyka ma na celu **zmniejszenie opóźnienia czasowego** między wykryciem pierwszych objawów a diagnozą [1, 9]. Modele ML mogą działać jako narzędzia wstępnego **skriningu** (przesiewowe) [4].
- **Optymalizacja zasobów klinicznych:** Usprawnienie pierwszych kroków diagnostycznych pozwala klinicystom **skoncentrować się na najbardziej złożonych przypadkach** [1, 9, 10].

2. Wykorzystanie danych cyfrowych i Big Data

Badania ML w psychiatrii dziecięcej wpisują się w szerszy nurt **Psycho-Informatyki** (Psycho-Informatics) [3, 10, 11], wykorzystując cyfrowo gromadzone dane:

- **Analiza danych kwestionariuszowych:** Celem jest analiza danych zbieranych zdalnie (online) za pomocą kwestionariuszy wypełnianych przez rodziców i nauczycieli [1, 2, 7, 12]. Badania mają na celu zrozumienie, w jakim stopniu informacje te **pokrywają się z konkluzjami diagnostycznymi klinicystów** [1, 2, 13].
- **Modelowanie procesu decyzyjnego klinicystów:** Użycie interpretowalnych algorytmów, takich jak DT, ma na celu **zasymulowanie klinicznego procesu klasyfikacji** ADHD/nie-ADHD i zidentyfikowanie reguł decyzyjnych, które klinicyści stosują w procesie diagnozy [1, 2, 13, 14].

3. Weryfikacja dokładności i generalizacja modeli

Istotnym celem badań jest zapewnienie, że opracowane modele są **dokładne, solidne i użyteczne** w praktyce klinicznej:

- **Osiąganie wysokiej dokładności predykcyjnej:** Modele ML, szczególnie RF, są rozwijane w celu osiągnięcia **wysokich wskaźników dokładności (accuracy)** i **czułości (sensitivity)** w klasyfikacji ADHD, co jest kluczowe dla rzetelności narzędzia screeningowego [15-17].
- **Porównanie i testowanie odporności modeli:** Badania porównują wydajność różnych algorytmów ML (np. DT, RF, SVM, LR), aby ocenić ich **zdolność do generalizacji** wyników (np. za pomocą walidacji krzyżowej), co symuluje przewidywania dla nowych pacjentów [1, 6, 15-19].
- Identyfikacja istotnych predyktorów i czynników zakłócających
- Badania ML mają również cel czysto naukowy, polegający na identyfikacji, które dane wejściowe są **najbardziej istotne dla diagnozy** [14, 20, 21]:
- **Określenie znaczenia cech:** Modele (np. za pomocą analizy SHAP w przypadku RF) identyfikują, które zmienne niezależne (np. płeć, ryzyko okołoporodowe, problemy rozwojowe) mają największą moc dyskryminacyjną w procesie klasyfikacji ADHD [12, 20-22].
- **Badanie korelacji z innymi zaburzeniami:** Celem jest również zbadanie, czy współwystępowanie objawów innych zaburzeń, np. **zaburzeń ze spektrum autyzmu (ASD)**, może stanowić **czynnik zakłócający (confounding factor)** przy ustalaniu nasilenia ADHD [1, 6, 23-25].

WEKA: Środowisko analizy wiedzy

Koncentrując się na oprogramowaniu wykorzystywanym w badaniach eksploracji danych, jakim jest WEKA, należy precyzyjnie wskazać jego twórców.

Oprogramowanie **WEKA** (Waikato Environment for Knowledge Analysis) zostało stworzone przez **University of Waikato w Nowej Zelandii** [1, 2].

Warto dodać, że WEKA jest popularną, otwartą aplikacją do eksploracji danych (*open-source data mining application*) [3]. W omawianych badaniach oprogramowanie to zostało wykorzystane do wstępnego przetwarzania i klasyfikacji zbiorów danych dotyczących ASD u dorosłych [3, 4].

Narodziny i Definicja Psycho-Informatyki

Szanowni studenci, w kontekście rewolucji, jaką Big Data i transfer technik informatycznych wnoszą do tradycyjnych nauk behawioralnych, pojawia się konieczność formalnego nazwania nowej, interdyscyplinarnej dziedziny.

Nowe pole badawcze, ustanowione przez transfer technik z informatyki (computer science) do psychiatrii i psychologii, nazywa się **Psycho-Informatyką** (ang. *Psycho-Informatics*) [1].

Dziedzina ta jest definiowana jako **zastosowanie Big Data w psychologii i psychiatrii** [1, 2]. Jej powstanie ma na celu fundamentalną zmianę metodologiczną i ma zrewolucjonizować te nauki, drastycznie wpływając na codzienną rutynę zarówno badaczy, jak i lekarzy [1, 3].

W przyszłości przewiduje się, że ta dziedzina może się rozwinąć w poddziedziny, takie jak **Psycho-Neuro-Informatyka** (ang. *Psycho-Neuro-Informatics*) [4, 5].

Bariery TeleNeuropsychologii: Finanse, Dostęp i Kultura

Przechodząc do praktycznych aspektów zastosowania nowych technologii w diagnostyce neuropsychologicznej, należy omówić kluczowe przeszkody, z jakimi wiąże się implementacja usług TeleNeuropsychologii (TeleNP).

Na podstawie źródeł można wskazać dwie główne bariery implementacji TeleNP, szczególnie w kontekście obsługi populacji w regionach wiejskich i słabo zaludnionych:

1. Bariery finansowe i administracyjne [1]

Wdrażanie TeleNP jest utrudnione przez czynniki ekonomiczne i problemy z ujednoliceniem procedur:

- **Brak zasobów finansowych i wsparcia administracyjnego:** Implementacja TeleNP wymaga dostępności zasobów finansowych i wsparcia administracyjnego w lokalnych klinikach, co często stanowi problem w regionach wiejskich [1].
- **Problemy z rozliczaniem i płatnościami (Billing Errors):** W trakcie projektu pilotażowego zaobserwowano błędy w rozliczeniach dokonywanych przez personel administracyjny, które nie zostały rozwiązane przez neuropsychologów. Kwestie te wymagały współpracy z działem finansowym w celu doprecyzowania wymogów rozliczeniowych i optymalizacji zwrotów kosztów [2]. W 2018 r. wyzwaniem było również uzyskanie płatności ubezpieczeniowych za TeleNP, które obejmowały znaczące ograniczenia w procedurach neuropsychologicznych (np. płatności tylko za badanie statusu neurobehawioralnego, CPT 96116) [3].
- **Konieczność dodatkowego szkolenia personelu:** Sukces wdrożenia TeleNP wymaga zatrudnienia i wyznaczenia dwujęzycznego (hiszpańsko-angielskiego) personelu administracyjnego, który specjalnie zarządzałby procesem TeleNP i planowaniem

wizyt, ponieważ dodatkowe obciążenie pracą biurową często nie było odpowiednio realizowane przez dotychczasowy personel [4].

2. Bariery dostępności technologii i czynniki socjokulturowe [5, 6]

Dostęp do usług TeleNP był ograniczony przez czynniki techniczne i związane z kontekstem życia pacjentów:

- **Brak dostępu do cyfrowego testowania i internetu:** Model TeleNP był ograniczony przez brak dostępu do cyfrowego testowania oraz czynniki socjokulturowe przyczyniające się do nieodpowiedniego domowego dostępu do internetu (szczególnie w kontekście transportu i obciążeń finansowych rodzin) [5].

• **Niechęć do telemedycyny i bariery komunikacyjne:** Osoby z niedostatecznie reprezentowanych grup mogą nie postrzegać telemedycyny jako preferowanej opcji w stosunku do wizyty osobistej. Mogą również odczuwać nieufność i dyskomfort związany z obecnością kamery [6]. Ponadto, czynniki takie jak niska świadomość zdrowotna (*low health literacy*) i problemy behawioralne podczas wideokonferencji komplikowały zdolność neuropsychologów do wydania ważnej, profesjonalnej opinii [7].

Krytyka Tradycyjnych Metod Psychometrii

W kontekście rewolucji, jaką niesie ze sobą Psycho-Informatyka i Big Data, należy dokładnie przeanalizować ograniczenia tradycyjnych metod psychometrycznych, które stanowią główną motywację do poszukiwania nowych rozwiązań.

Zgodnie ze źródłami, dwie główne wady tradycyjnej psychometrii, opartej na obserwacjach klinicystów i testach samooceny, to:

1. Niska jakość i zniekształcenie zbieranych danych (Bias and Distortion)

Tradycyjne metody gromadzenia danych, takie jak samoocena (self-reports) i kwestionariusze, są podatne na błędy, ponieważ:

- **Zniekształcone przypominanie (Poor Recollection):** Uczestnicy często błędnie lub niedokładnie przypominają sobie zmienne będące przedmiotem zainteresowania, zwłaszcza gdy interwały raportowania są długie. Jest to szczególnie widoczne w przypadku interakcji z urządzeniami cyfrowymi; niewiele osób potrafi dokładnie podać, jak często sprawdzało e-mail w ciągu ostatnich 10 dni [1, 2].
- **Wpływ aktualnego stanu psychicznego:** Raporty dotyczące subiektywnego dobrostanu mają tendencję do odzwierciedlania zmienionego stanu afektywnego w momencie raportowania. Na przykład, pacjent w depresji zazwyczaj oceni swoje samopoczucie, funkcjonowanie społeczne i warunki życia jako gorsze, niż widziałby je niezależny obserwator lub on sam po wyzdrowieniu [1].
- **Wpływ pożądania społecznego (Social Desirability):** Na samoocenę wpływa również pożądanie społeczne zgłaszanego zachowania [1].

- **Subiektywność oceny eksperta:** Nawet testy psychometryczne oceniane przez klinicystów niosą ryzyko stronniczości, ponieważ oceny ekspertów nie są całkowicie obiektywne [1].

2. Niewystarczająca ilość i zbyt niska ziarnistość czasowa danych (Quantity and Coarse Temporal Granularity)

Tradycyjne metody zbierania danych cechują się małą ilością danych i nie są w stanie uchwycić dynamicznych, drobnoziarnistych wzorców:

- **Zbyt gruba ziarnistość czasowa:** Granularność czasowa, z jaką tradycyjne metody zbierają dane (np. cotygodniowe lub comiesięczne kwestionariusze), jest zbyt niska, aby ujawnić drobnoziarniste wzorce [3, 4]. Wymaganie częstych wywiadów byłoby zbyt drogie i uciążliwe dla pacjentów [5].
- **Kwestie praktyczne i ekonomiczne:** Całodobowe obserwowanie pacjenta (shadowing) nie jest ani akceptowalne dla uczestnika, ani opłacalne finansowo [3]. Ponadto nie można wielokrotnie w ciągu jednego dnia przeprowadzać identycznych testów psychometrycznych ze względu na efekty pamięci i uczenia się, co ogranicza wiarygodność [3].
- **Płytkie skale pomiarowe:** Tradycyjne metody często używają płytkich skal, co prowadzi do szybkich efektów pułapu (floor effects). Przykładowo, większość kwestionariuszy dotyczących depresji pozwala na odpowiedzi na skali tylko od 0 do 3, co dramatycznie wpływa na możliwość wiarygodnego ilościowego określenia pozytywnych efektów nowych substancji psychotropowych [4].

Podsumowując, tradycyjne metody słabo oddają rzeczywistą sytuację pacjenta lub uczestnika badania, ponieważ dane są zbyt rzadkie, brakuje im dynamiki, a ich jakość jest obniżona przez subiektywne błędy i zniekształcenia [1, 4, 6]. Nowe podejście Psycho-Informatyki dąży do przezwyciężenia tych ograniczeń poprzez wykorzystanie urządzeń cyfrowych do automatycznego i nieobciążającego zbierania danych o najwyższej jakości i precyzyjnej rozdzielczości czasowej [6, 7].

Psycho-Informatyka: Cyfrowa Transformacja Psychologii i Psychiatrii

Głównym celem i definicją **Psycho-Informatyki** (ang. *Psycho-Informatics*) jest **zastosowanie Big Data w psychologii i psychiatrii** [1].

Ta nowa, autonomiczna dziedzina badań [2] ma na celu wywołanie **największej pojedynczej zmiany metodologicznej** (single biggest methodological shift) od momentu powstania psychologii i psychiatrii [1, 2].

Kluczowe cele i konsekwencje

1. **Fundamentalna zmiana metodologiczna:** Głównym celem Psycho-Informatyki jest **zrewolucjonizowanie psychiatrii i psychologii** [3]. Osiąga się to poprzez transfer technik z informatyki do psychiatrii i psychologii [2].
2. **Wpływ na rutynę kliniczną i badawczą:** Oczekuje się, że wynikający z niej zakres zastosowań **drastycznie ukształtuje codzienne rutyny** zarówno badaczy, jak i lekarzy [2].
3. **Kontekst cyfryzacji:** Psycho-Informatyka jest również określana jako **przejście na cyfryzację** w praktyce klinicznej [4], co jest ułatwione przez stopniowe włączanie **urządzeń obliczeniowych** do klinicznych procesów pracy [4, 5].

Psycho-Informatyka jest zatem podejściem, które ma na celu wykorzystanie potencjału Big Data do tworzenia nowej ramy obliczeniowej, wspierającej dokładniejszą i szybszą diagnostykę oraz leczenie w psychopatologii [6-8].

Cyfrowy ślad autyzmu: Narodziny zbioru danych UCI

Aplikację mobilną o nazwie **"ASD Tests"** (*Surveys on a mobile application called "ASD Tests"*) wymyślił **Dr Fadi Fayez** [1].

W momencie zbierania danych na potrzeby badań naukowych, Dr Fadi Fayez był związany z **Nelson Marlborough Institute of Technology** [1].

Aplikacja ta była używana do zbierania danych z różnych krajów za pomocą ankiet dotyczących zaburzenia ze spektrum autyzmu (ASD) [1]. Aplikacja była wspierana przez systemy operacyjne iOS i Android [1]. Warto zaznaczyć, że chociaż dane zbierane tą metodą były obszerne, nie były kompletne (niektóre rekordy danych mogły nie mieć wartości, ponieważ były opcjonalne), a zatem zebrane informacje nie były wystarczająco wiarygodne, aby mogły być bezpośrednio wykorzystane do podejmowania decyzji terapeutycznych [1]. Dane te zostały następnie wykorzystane do stworzenia zbioru danych **ASD dataset z bazy UCI** [1].

Cyfrowy ślad: pomiar depresji przez smartfony

Smartfony były wykorzystywane do dynamicznego monitorowania i ilościowego określania ciężkości dużej depresji (Major Depressive Disorder, MDD) [1, 2].

W ramach badań logowano i analizowano interakcje użytkowników ze smartfonami [2, 3]. W szczególności, u pacjentów z depresją monitorowano trzy główne kategorie danych behawioralnych [2]:

1. Użycie aplikacji (App Usage) Monitorowanie użycia aplikacji miało na celu rejestrowanie „sesji aplikacji” (*app-session*), czyli interwału czasowego, podczas którego użytkownik aktywnie wchodził w interakcję z daną aplikacją działającą na pierwszym planie [4].

• Rejestrowano **nazwę aplikacji, czas rozpoczęcia i czas zakończenia sesji** [4].

• Traktowano ekran blokady i główne menu jako dodatkowe aplikacje [4].

• Rejestrowano, **jak często użytkownik włączał telefon** (bez faktycznego odblokowywania) [4].

• Rejestrowano, **ile czasu użytkownik spędzał w głównym menu** [4].

2. Interakcje społeczne i wzorce komunikacji (Social Interaction) Monitorowano wzorce komunikacji w celu wywnioskowania **rozmiaru i sposobu użycia sieci społecznościowej użytkownika** [5]. Rejestrowano [5]:

• **Połączenia telefoniczne i wiadomości SMS** (przychodzące i wychodzące) [5].

• Dokumentowano, **z iloma kontaktami użytkownik regularnie wchodził w interakcję** [5].

• Rejestrowano, **kto inicjował komunikację** [5].

• Numery telefonów były anonimizowane za pomocą kryptograficznych funkcji skrótu (SHA-512) [5].

• Monitorowano **książkę adresową** telefonu, aby oszacować **całkowitą liczbę kontaktów** oraz **frakcję, z którą użytkownik aktywnie się komunikuje** [5].

• W przypadku SMS-ów rejestrowano również **długość wiadomości** w znakach oraz **czas wysłania/otrzymania i odczytania** [5].

3. Makro-ruch (Macro Movement) Regularnie rejestrowano **pozycję geograficzną użytkownika**, co było istotne w kontekście ciężkiej depresji, aby sprawdzić, czy pacjent **w ogóle opuszcza mieszkanie** [6].

• Lokalizację szacowano za pomocą **GPS co 20 minut** [6].

• Rejestrowane dane zawierały **czas, szerokość i długość geograficzną oraz dokładność** [6].

• Lokalizację szacowano również za pomocą **dostępnych sygnałów Wi-Fi i triangulacji wież telefonii komórkowej** [6].

Dane te miały odzwierciedlać **zmniejszoną energię i dynamikę**, a także anhedonię i wycofanie społeczne, które są centralnymi objawami depresji [2]. Dodatkowo, pojawiające się badania nad depresją badały korelacje między objawami nastroju a **danymi lokalizacyjnymi GPS**, ujawniając dużą ilość prywatnych informacji, takich jak miejsca pracy, zamieszkania i robienia zakupów [7].

Fundamenty Psycho-Informatyki

Transfer technik informatycznych do psychiatrii oraz psychologii ustanawia zupełnie nową, autonomiczną dziedzinę badań (ang. *research direction*), którą nazwano **Psycho-Informatyką** (ang. *Psycho-Informatics*) [1-3].

Psycho-Informatyka jest definiowana jako **zastosowanie Big Data w psychologii i psychiatrii** [3] i ma na celu fundamentalną zmianę metodologiczną w tych naukach [2, 3].

Kluczowe aspekty tej dziedziny:

- **Geneza:** Powstanie Psycho-Informatyki jest wynikiem **transferu technik z informatyki do psychiatrii i psychologii** [1].
- **Kontekst cyfryzacji:** Przejście na cyfryzację w praktyce klinicznej, ułatwione przez stopniowe włączanie urządzeń obliczeniowych do procesów pracy klinicznej, jest określane jako **psycho-informatyka** [4, 5].
- **Wpływ:** Oczekuje się, że to podejście zrewolucjonizuje psychiatrię i psychologię oraz drastycznie wpłynie na codzienną rutynę zarówno badaczy, jak i lekarzy [1, 2].
- **Obszary powiązane:** W przyszłości mogą pojawić się poddziedziny, takie jak **Psycho-Neuro-Informatyka** [6].

W ramach tej dziedziny wykorzystuje się zaawansowane metody klasyfikacji psychopatologii, takie jak nadzorowane uczenie maszynowe (ML), do analizy danych zebranych cyfrowo w celu wsparcia diagnozy [4, 7].

Korekcja Nierównowagi Klas Zastosowaniem SMOTE

Techniką wykorzystaną do **skorygowania nierównowagi** w zbiorze danych (gdzie pacjenci z ASD stanowili klasę mniejszościową [1-3]) podczas klasyfikacji zaburzenia ze spektrum autyzmu (ASD) była **syntetyczna metoda nadpróbkowania (SMOTE)**, co jest skrótem od *Synthetic Oversampling Approach* [1-4].

Poniżej przedstawiono szczegóły dotyczące zastosowania tej metody:

- **Cel:** Metoda SMOTE została zastosowana, ponieważ w oryginalnym zbiorze danych (pochodzącym z bazy UCI dla dorosłych) **pacjenci z ASD stanowili klasę mniejszościową** [2, 3]. Zbiór danych składał się z 515 zdrowych osób kontrolnych i 189 pacjentów z ASD [5]. Zastosowanie SMOTE miało na celu **poprawienie danych** i **skorygowanie nierównowagi** [1-3].
- **Współczynnik nadpróbkowania:** W badaniu SMOTE został użyty do wyrównania częstości występowania w klasie mniejszościowej (pacjenci z autyzmem) ze **współczynnikiem (procentem) 175%** [3].
- **Kontekst użycia:** Technika SMOTE została wykorzystana podczas etapu wstępnego przetwarzania cech (Preprocessing of Features) w środowisku **WEKA** (Waikato Environment for Knowledge Analysis) [1, 6].
- **Procedura:** Parametry klasyfikatora i ilość nadpróbkowania (oversampling) zostały ustalone przy użyciu metody **przeszukiwania siatki (grid search approach)** oraz **10-krotnej walidacji krzyżowej (10-fold cross-validation)**, co miało na celu uniknięcie nadmiernego dopasowania (overfitting) i stronniczości (bias) w analizach klasyfikacyjnych [2, 3].
- **Efekt:** Zastosowanie SMOTE pozwoliło na **wyrównanie częstości** klas w zbiorze uczącym (training set) [3].

Podsumowując: SMOTE jest techniką syntetycznego nadpróbkowania, która resampluje zbiór danych poprzez zastosowanie syntetycznego nadpróbkowania mniejszości [3].

WEKA: Klasyfikacja i Przetwarzanie Danych ASD

W badaniu dotyczącym wykrywania zaburzenia ze spektrum autyzmu (ASD) u dorosłych poprzez eksplorację danych, do **klasyfikacji i wstępnego przetwarzania** zbiorów danych wykorzystano oprogramowanie **WEKA** [1-3].

WEKA (Waikato Environment for Knowledge Analysis) to pakiet uczenia maszynowego (machine learning program), który pozwala na łączne wykorzystanie różnych narzędzi w celu przeprowadzenia szeroko zakrojonych porównań różnych metodologii [4]. Jest to popularna, **otwarta aplikacja do eksploracji danych** (*open-source data mining application*) [3, 4], opracowana przez University of Waikato w Nowej Zelandii [3].

W ramach badania, oprogramowanie WEKA (wersja 3.8.4) zostało użyte do:

1. **Wstępnego przetwarzania danych** (*Preprocessing of Features*) ze zbioru danych ASD dla dorosłych z bazy UCI [2, 4].
2. **Kategoryzacji danych** (Classification) [2].
3. **Zaimplementowania czterech porównywanych klasyfikatorów** (LR, SMO, Naïve Bayes, IBK) w celu rozróżnienia dorosłych z autyzmem od zdrowych osób kontrolnych [1-3].
4. **Zastosowania techniki SMOTE** (Synthetic Oversampling Approach) do skorygowania nierównowagi danych w klasie mniejszościowej (pacjenci z ASD) [2, 5-7].

Wykresy w źródłach ilustrują również, że zarówno **wstępne przetwarzanie cech**, w tym SMOTE i 10-krotna walidacja krzyżowa, jak i końcowa **klasyfikacja**, odbywały się w środowisku **WEKA** [2, 4, 6, 8].

Algorytmy Uczenia Maszynowego w Diagnostyce Autyzmu Dorosłych

W badaniu dotyczącym wykrywania zaburzenia ze spektrum autyzmu (ASD) u dorosłych za pomocą eksploracji danych porównano wydajność czterech potencjalnych klasyfikatorów [1, 2]:

1. **Regresja logistyczna (LR)** [1, 3].
2. **Sekwencyjna minimalna optymalizacja (SMO)** (ang. *Sequential Minimal Optimization*) [1, 3].
3. **Naïve Bayes** [1, 3, 4].
4. **Technika oparta na instancji (IBK)** oparta na k-najbliższych sąsiadach (ang. *instance-based technique based on k-neighbors* lub *k-nearest-neighbors classifier*) [1, 3-5].

Klasyfikatory te zostały zastosowane za pomocą narzędzi **WEKA** (Waikato Environment for Knowledge Analysis) w celu odróżnienia dorosłych z autyzmem od zdrowych, normalnych osób [1, 2].

Eksploracja Danych: Psychometria i Diagnostyka Kliniczna

Eksploracja danych (ang. *Data Mining*) jest kluczową koncepcją w kontekście wykorzystania dużych zbiorów danych (Big Data) w psychometrii i diagnostyce klinicznej [1-3].

Źródła definiują eksplorację danych w następujący sposób:

1. Ogólna definicja (cel i rezultat)

Eksploracja danych jest metodologią polegającą na **identyfikowaniu trendów i wzorców w danych** [4].

- Celem eksploracji danych jest **wyodrębnienie informacji** ze zbioru danych i przekształcenie jej w **zrozumiałe dane**, aby pomóc użytkownikom w podejmowaniu lepszych decyzji [4].
- Odkryte wzorce muszą być **użyteczne** w tym sensie, że skutkują **zyskiem** [4].
- Jest to kluczowa czynność polegająca na **wyciąganiu wniosków w oparciu o zebrane dane** [5].

2. Definicja w kontekście Big Data (badanie wzorców)

W szerszym kontekście Big Data, gdzie dane są zbierane z wielu źródeł bez natychmiastowego celu biznesowego, eksploracja danych jest jedną z głównych dyscyplin analitycznych:

- Aplikacje Big Data koncentrują się na analizie danych, a badacze starają się **wykryć nieznane dotąd trendy i wzorce** [6].
- Dyscyplina ta, określana mianem eksploracji danych (*data mining*), jest używana w celu generowania obserwacji, takich jak np. „klienci, którzy kupują chleb i masło, zazwyczaj kupują też piwo” (analiza koszyka rynkowego) [6].
- Eksploracja danych i Big Data są często używane zamiennie [2]. W kontekście psychometrii, Big Data jest definiowane jako **unia narzędzi i dyscyplin** zaangażowanych w zbieranie, przechowywanie i analizowanie dużych ilości danych pochodzących z obserwacji interakcji między użytkownikami a urządzeniami (np. telefonami), co obejmuje także eksplorację danych [3].

3. Eksploracja danych jako element metodologii (ASD)

W kontekście badań nad zaburzeniem ze spektrum autyzmu (ASD) eksploracja danych (DM) jest wykorzystywana jako **metodologia, która ma za zadanie pomóc w szybkiej, akceptowalnej i łatwej diagnostyce** [7, 8].

- W badaniu nad wykrywaniem ASD DM została użyta do oceny wydajności klasyfikatorów LR, SMO, Naiwnego Bayesa i IBK w celu rozróżnienia dorosłych osób z autyzmem od zdrowej grupy kontrolnej [7-9].
- Metodologia eksploracji danych jest metodą **identyfikowania trendów w danych**, a w kontekście tego badania obejmuje etapy wstępnego przetwarzania i kategoryzacji [4].

SMO: Klasyfikacja ASD z dokładnością 99,71%

Dokładność klasyfikacji osiągnięta przez metodę **SMO** (Sequential Minimal Optimization) w badaniu nad wykrywaniem zaburzenia ze spektrum autyzmu (ASD) u dorosłych wyniosła **99,71%** [1, 2].

Model SMO, który jest techniką optymalizacji minimalnej sekwencyjnej w klasyfikacji wektorów nośnych (Support Vector Classification) [3], osiągnął najwyższą dokładność spośród czterech badanych klasyfikatorów: Logistic Regression (LR), Naïve Bayes i Instance-Based technique opartych na k-sąsiadach (IBK) [4, 5].

Szczegóły wyników SMO:

- **Dokładność klasyfikacji: 99,71%** [1, 2].
- **Czułość (Sensitivity):** 100% [2].
- **Specyficzność (Specificity):** 99% [2].

W klasyfikacji z użyciem SMO, 515 pacjentów zostało prawidłowo sklasyfikowanych jako grupa kontrolna, a 516 z 519 pacjentów z ASD zostało prawidłowo zdiagnozowanych jako pacjenci z ASD [6].

Model SMO w tym badaniu przewyższył dokładność innych testowanych klasyfikatorów [1, 5]:

- Naïve Bayes: 98,74% dokładności [6, 7].
- Regresja logistyczna (LR): 98,16% dokładności [2, 8].
- IBK: 97,39% dokładności [5, 9].

Do testów wykorzystano zestawy danych ASD dla dorosłych (powyżej 18 roku życia, AQ-10-Adult) z bazy UCI, które zostały wstępnie przetworzone i sklasyfikowane za pomocą narzędzi WEKA [10-12]. Do korekty nierównowagi klas (ASD jako mniejszość) zastosowano metodę sztucznego nadpróbkowania (SMOTE) [11, 13, 14].

Czułość Klasyfikatora: Definicja i Równanie

Według równania (3) ze źródeł, **czułość** (ang. *Sensitivity* lub *Recall*) to miara wydajności klasyfikatora, która jest zdefiniowana jako **procent poprawnie wykonanych pozytywnych przewidywań** w stosunku do całkowitej liczby obiektów, które faktycznie mają tę diagnozę [1, 2].

Równanie (3) ma następującą postać [1]:

textCzułos´c´(recall)=fracTPTP+FN

Gdzie:

- **TP** (True Positive, pol. Prawdziwie Pozytywny) oznacza obiekty, które klinicyści zdiagnozowali jako **pozytywne** (np. z ADHD lub ASD) i które klasyfikator AI **poprawnie** zaklasyfikował jako pozytywne [3, 4].
- **FN** (False Negative, pol. Fałszywie Negatywny) oznacza obiekty, które klinicyści **zdiagnozowali** jako pozytywne (np. z ADHD lub ASD), ale które klasyfikator AI **błędnie** zaklasyfikował jako negatywne (np. "non-ADHD") [3, 4].

Innymi słowy, **czułość (recall)** określa zdolność modelu do znajdowania **wszystkich istotnych przypadków** (w tym kontekście – wszystkich pacjentów z danym zaburzeniem) w zbiorze danych [5]. Jest to jeden z elementów macierzy pomyłek (ang. *confusion matrix*) wykorzystywanej do oceny wydajności klasyfikatora [5].

Niedoskonałości pomiaru psychologicznego

Dwie główne wady tradycyjnej psychometrii, opartej na obserwacjach klinicystów i samooocenianych testach psychometrycznych, dotyczą jakości i ilości zbieranych danych [1].

Oto dwie kluczowe wady:

1. Niska jakość i stronniczość (Bias and Poor Quality)

Dane zbierane tradycyjnymi metodami są **silnie stronnicze** (strongly biased) [2] oraz **wadliwe i zniekształcone** (faulty and distorted) [2].

• **Słaba pamięć i subiektywność:** Raporty oparte na samoocenie są często zniekształcone z powodu **słabej pamięci** (poor recollection) osoby badanej, szczególnie w przypadku raportowania w dłuższych interwałach [2]. Ponadto, samooceny mają tendencję do odzwierciedlania **zmienionych stanów psychicznych** (altered psychological states) w momencie raportowania, co wprowadza znaczący szum do danych rejestrowanych rzadko [2]. Na przykład, pacjent w depresji zazwyczaj gorzej oceni swoje samopoczucie czy funkcjonowanie społeczne, niż zrobiłby to niezależny obserwator [2].

- **Stronniczość oceny klinicznej:** Testy oceniane przez klinicystów również wiążą się z ryzykiem błędu, ponieważ oceny ekspertów nie są całkowicie obiektywne i mogą odzwierciedlać **subiektywny punkt widzenia oceniającego** (subjective view of the assessor himself) [2].

2. Niska granularność czasowa i wysoki koszt

Tradycyjne metody zbierają dane o zbyt niskiej granularności czasowej, a ich stosowanie jest nieefektywne kosztowo [3, 4].

• **Zbyt niska granularność czasowa:** Zbieranie danych odbywa się w interwałach, które są zazwyczaj **zbyt niskiej granularności** (too coarse granularity) [3, 4] (np. tygodniowo, miesięcznie lub rzadziej) [3]. Utrudnia to uchwycenie dynamiki i **drobnoziarnistych wzorców** (fine-granular patterns) [3, 4]. Jest to problematyczne, ponieważ ze względu na efekty pamięci i treningu nie jest możliwe wielokrotne przeprowadzanie tego samego testu psychometrycznego w ciągu jednego dnia [3].

• **Wysokie koszty:** Prowadzenie częstych wywiadów jest **prohibitywnie drogie** (prohibitively expensive), ponieważ muszą być one przeprowadzane przez przeszkolonego specjalistę [3]. W związku z tym, ograniczenia finansowe i logistyczne ograniczają ilość i kompletność danych zbieranych w badaniach podłużnych [1, 5]. Zebrane w ten sposób dane "źle oddają sytuację uczestnika badania lub pacjenta" [4].

Pułapki Pomiaru Nasilenia Objawów ADHD

Ocena ciężkości objawów zaburzenia nadpobudliwości psychoruchowej z deficytem uwagi (ADHD) jest utrudniona z powodu kilku czynników związanych z naturą samego zaburzenia neurorozwojowego (NDD), współwystępującymi schorzeniami oraz ograniczeniami tradycyjnych metod pomiaru. Kluczowe czynniki utrudniające ocenę ciężkości objawów ADHD, zidentyfikowane w źródłach, to:

1. Współistnienie objawów innych zaburzeń

Najważniejszym czynnikiem zakłócającym jest **współwystępowanie objawów zaburzenia ze spektrum autyzmu (ASD)**, które mogą być **czynnikiem zakłócającym (confounding factor)** podczas ustalania ciężkości objawów ADHD [1].

- Istnieje **znaczne behawioralne nakładanie się** (considerable behavioral overlap) między ASD i ADHD [2].
- Nietypowe cechy funkcjonowania społecznego (social functioning atypicalities), będące cechą charakterystyczną ASD, są **często zgłaszane również w ADHD** [3].
- Na poziomie fenotypowym, upośledzenie społeczne w obu schorzeniach może wyglądać **podobnie** dla klinicystów i osób niebędących klinicystami [3].
- Rodzice dzieci skierowanych z podejrzeniem ADHD mogą zgłaszać upośledzone funkcjonowanie społeczne, co **wpływa na wyniki** (diagnostic decisions) [3].
- Modele AI wykazały tendencję do klasyfikowania pacjentów jako mających ADHD, gdy rodzice zgłaszali **podwyższone objawy ASD** [4].
- W badaniu stwierdzono, że rodzice i nauczyciele dostarczali **bardziej nasilone oceny objawów ADHD** u dzieci, u których klinicyści ostatecznie zdiagnozowali współwystępujące ADHD–ASD [5].

2. Ograniczenia tradycyjnych metod psychometrycznych

Tradycyjna metodologia oceny behawioralnej i psychologicznej, na której opiera się diagnoza ADHD, ma kilka wbudowanych wad [6, 7]:

- **Subiektywność samoocen:** Pacjenci lub ich opiekunowie polegają na samoopisie, który jest **silnie stronniczy, wadliwy i zniekształcony** z powodu **słabej pamięci** (poor recollection), zwłaszcza przy rzadkim raportowaniu [7]. Co więcej, samooceny mają tendencję do odzwierciedlania **zmienionych stanów psychicznych** (altered psychological states) w momencie raportowania [7].
- **Subiektywność oceny klinicznej:** Testy oceniane przez klinicystów również wiążą się z ryzykiem błędu, ponieważ oceny ekspertów nie są całkowicie obiektywne i mogą odzwierciedlać **subiektywny punkt widzenia oceniającego** [7].
- **Niejednoznaczność diagnostyczna:** Większość NDD, w tym ADHD, diagnozuje się na podstawie **obecności progowej liczby objawów** zidentyfikowanych poprzez obserwację bezpośrednią lub wywiad [8]. To powoduje, że **wiarygodność dostępnych informacji jest zmienna** (will vary) w zależności od osoby, a opinia eksperta może się różnić, przez co orzeczenie diagnostyczne często nie jest definitywne [8].
- **Niska szczegółowość danych (Coarse Granularity):** Tradycyjne metody zbierają dane o zbyt **niskiej granularności czasowej** (zwykle co tydzień, co miesiąc lub rzadziej), aby wykryć drobnoziarniste wzorce [9, 10].
- **Zmienność w czasie:** Obraz kliniczny zaburzeń neurorozwojowych **może zmieniać się w czasie** (vary over time) ze względu na rozwojowy charakter tych schorzeń [8].
- **Płytkie skale:** Kwestionariusze często wykorzystują **płytkie skale** (shallow scales), co może prowadzić do efektów pułapu (floor effects), utrudniając wiarygodne ilościowe określenie pozytywnych efektów lub zmian w nasileniu objawów [11].

3. Złożoność zbioru danych

Nawet przy użyciu nowoczesnych narzędzi, takich jak AI, istnieją trudności związane z danymi wykorzystywanymi do oceny:

- Zmienne predykcyjne zidentyfikowane przez modele AI opierające się **wyłącznie na informacjach socjo-anamnestycznych** (np. płeć, ryzyko przed- i okołoporodowe) mogą być silne w klasyfikacji, ale niekoniecznie odzwierciedlają **bezpośrednio nasilenie objawów** behawioralnych [12].
- Modele oparte na danych behawioralnych zebranych zdalnie mogą napotkać trudności, ponieważ **niekontrolowane warunki administracji** ankiet mogą wpływać na ważność samoocenianych danych [13].

Podsumowując, problem w ocenie ciężkości objawów ADHD leży w fakcie, że zarówno klinicyści, jak i algorytmy uczenia maszynowego opierają się na **subiektywnych raportach** [7, 8], które są **zniekształcone przez słabą pamięć, subiektywny stan psychiczny** [7] oraz **nakładające się fenotypy** współistniejących zaburzeń, zwłaszcza ASD [1, 2].

Predykcja ADHD: Zmienne krytyczne według typu danych AI

Pytanie o najlepszą zmienną przewidującą diagnozę ADHD (Attention-Deficit/Hyperactivity Disorder) zależy od rodzaju analizowanych danych. Źródła wskazują na dwa różne, ale kluczowe czynniki predykcyjne w zależności od tego, czy model AI wykorzystuje skale behawioralne i kliniczne, czy tylko dane społeczno-anamnestyczne.

1. Na podstawie danych z kwestionariuszy objawów (skale kliniczne)

W badaniach symulujących proces decyzyjny klinicystów za pomocą algorytmu **Decision Tree (DT)**, który opierał się na cyfrowo zebranych kwestionariuszach objawów (np. skalach Connersa) od rodziców i nauczycieli, zmienną najbardziej różnicującą i najlepiej przewidującą diagnozę ADHD była:

- **Nasilenie podstawowych objawów ADHD zgłaszanych przez opiekunów** [1, 2]. Ta informacja okazała się najbardziej **dyskryminująca** dla klinicystów w procesie diagnostycznym [1, 2].
- Oceny w **skalach ADHD ukierunkowanych na kryteria DSM** (zarówno rodziców, jak i nauczycieli) wykazały kluczowe znaczenie dla decyzji diagnostycznej klinicystów [2].
- Konkretnie, w modelu Decision Tree (DT) symulującym decyzje diagnostyczne, algorytm wykorzystał **CPRS-R DSM – Combined** (skala oceny rodziców Connersa, kategoria Combined według DSM) jako pierwszy podział (węzeł główny), co oznacza, że była to **najważniejsza pojedyncza zmienna** w hierarchii decyzyjnej [3].

Modele DT osiągnęły bardzo dobrą dokładność (82%) w prawidłowym identyfikowaniu dzieci z ADHD lub bez ADHD w zbiorze uczącym [4]. Co więcej, w górnych węzłach drzewa decyzyjnego, algorytm DT identyfikował progi punktowe, które były zgodne z umiarkowanym i ciężkim ryzykiem ADHD (odpowiednio 64 i 70) [5].

2. Na podstawie danych społeczno-anamnestycznych (czynniki ryzyka)

W innym badaniu wykorzystującym zaawansowane modele uczenia maszynowego, w tym **Random Forest (RF)**, do klasyfikacji ADHD i ASD, ale opartym **wyłącznie na informacjach społeczno-anamnestycznych** zgłaszanych przez rodziców (z wykluczeniem bezpośrednich skal objawów) [6, 7]:

- Model RF, osiągający 84% dokładności klasyfikacji ADHD [8], zidentyfikował **płeć (Sex)** jako najsilniejszą zmienną predykcyjną [9].
- Analiza SHAP (Shapley additive explanations) wykazała, że **płeć** miała zdecydowanie **najwyższą zdolność dyskryminacyjną** spośród analizowanych czynników ryzyka przy klasyfikacji ADHD [9, 10].
- Kolejnymi wpływowymi predyktorami dla ADHD (po płci) była obecność **ryzyka przed- i okołoporodowego (Pre- and perinatal risk)** oraz **obawy rozwojowe (Developmental concerns)** [9, 10].
- Model **regresji logistycznej (LR)** również wskazał płeć jako najsilniejszy predyktor dla ADHD (współczynnik szans, OR = 2.14) [11]. Jest to zgodne z faktem, że płeć męska jest bardziej narażona na diagnozę ADHD [9, 12].

Podsumowując, jeśli chodzi o *samodzielne dane kliniczne* (raporty objawów), **nasilenie podstawowych objawów ADHD** jest kluczowym predyktorem [1]. Jeśli natomiast weźmiemy pod uwagę *tylko dane dotyczące ryzyka demograficznego i anamnestez* (bez bezpośrednich skal objawów), **płeć** jest najlepszą zmienną przewidującą diagnozę ADHD [9, 11].

Las Losowy: Precyzja w Cyfrowej Klasyfikacji ADHD

Najbardziej efektywną metodą do diagnozowania (klasyfikowania) ADHD, opartą na analizie danych zebranych cyfrowo, okazał się model **Random Forest (RF)** [1, 2].

W badaniu, które wykorzystywało modele uczenia maszynowego (ML) do różnicowania zaburzeń neurorozwojowych na podstawie danych społeczno-anamnestycznych zgłaszanych przez rodziców za pośrednictwem internetowej platformy przesiewowej (MedicalBIT), osiągnięto następujące wyniki dla klasyfikacji ADHD:

- **Random Forest (RF):** Osiągnął **84% dokładności** klasyfikacji (95% CI 82-85; *P* <.001) [1-3]. Model RF wykazał również wysoką czułość (sensitivity) wynoszącą **93%** [1, 3].
- **Decision Tree (DT):** Osiągnął 74% dokładności (95% CI 71-77; *P* <.001) [1, 4].
- **Logistic Regression (LR):** Osiągnął 61% dokładności (95% CI 57-64; *P* <.001) [1, 5].
- Model Random Forest przewyższył zarówno model Decision Tree, jak i model Logistic Regression pod względem osiągniętej dokładności w kategoryzacji ADHD [1, 2, 6].
- Inne analizowane metody oparte na kwestionariuszach
- W innym badaniu, które również wykorzystywało dane zebrane zdalnie (kwestionariusze objawów zgłaszane przez rodziców i nauczycieli) w celu symulacji procesu klinicznego diagnostyki ADHD, porównano kilka algorytmów uczenia maszynowego:
- **Decision Tree (DT):** Osiągnął **82% dokładności** w identyfikacji reguł decyzyjnych klinicystów w zbiorze treningowym [7, 8]. W eksperymencie z walidacją krzyżową (cross-validation) model DT osiągnął **74% dokładności predykcyjnej** [7, 9].
- **Random Forest (RF):** W tym samym eksperymencie z walidacją krzyżową osiągnął **74% dokładności** [7, 9].
- **Support Vector Machines (SVM):** W tym samym eksperymencie z walidacją krzyżową osiągnął **75% dokładności** [7, 9].

Należy zaznaczyć, że chociaż Decision Tree jest łatwo interpretowalny (co jest kluczowe w kontekście wspierania decyzji klinicznych), to bardziej złożone metody, takie jak Random Forest (RF), generalnie wykazują wyższą precyzję klasyfikacji, skutecznie wychwytując skomplikowane relacje w danych [2, 10].

Optymalizacja Diagnozy Autyzmu Metodą SMO

Klasyfikatorem, który osiągnął **99,71% dokładności** diagnozowania zaburzenia ze spektrum autyzmu (ASD) u dorosłych, jest **SMO** (Sequential Minimal Optimization) [1-4].

Badanie, w którym osiągnięto ten wynik, miało na celu porównanie skuteczności czterech klasyfikatorów w wykrywaniu ASD u dorosłych na podstawie cyfrowo zebranych danych: regresji logistycznej (LR), Sequential Minimal Optimization (SMO), Naiwnego Bayesa (Naïve Bayes) oraz metody opartej na instancji k-najbliższych sąsiadów (IBK) [2, 5-7].

Szczegółowe wyniki klasyfikatorów:

Klasyfikator	Dokładność klasyfikacji	Czułość (Sensitivity)	Specyficzność (Specificity)
SMO	**99,71%** [1, 3, 4]	100% [3]	99% [3]
Naïve Bayes	98,74% [8]	98% [8]	99% [8]
LR (Regresja logistyczna)	98,16% [9]	98% [9]	99% [9]
IBK (k-NN)	97,39% [10]	96% [10]	99% [10]

Wyniki te wyraźnie pokazały, że dokładność klasyfikacji osiągnięta przez SMO przewyższyła dokładność pozostałych badanych klasyfikatorów [1, 4, 11]. Wnioski z badania sugerują, że SMO ma potencjał do znacznej poprawy istniejących metod kategoryzacji ASD w zastosowaniach medycznych [4, 11].

W klasyfikacji za pomocą SMO prawidłowo skategoryzowano 515 osób jako grupę kontrolną i 516 z 519 jako pacjentów z ASD (na podstawie macierzy pomyłek) [8]. Dane użyte do klasyfikacji pochodziły ze zbioru danych dla dorosłych (powyżej 18 roku życia, AQ-10-Adult) z bazy UCI, który został przetworzony i sklasyfikowany przy użyciu narzędzi WEKA [6, 7, 12]. Do skorygowania nierównowagi danych, gdzie pacjenci z ASD stanowili mniejszość, zastosowano metodę sztucznego nadpróbkowania (SMOTE) [6, 13, 14].

Model SMO, który jest metodą optymalizacji minimalnej sekwencyjnej (Sequential Minimal Optimization) w klasyfikacji wektorów nośnych (Support Vector Classification), rozbija problem optymalizacji wielozmiennej na serię podproblemów [15].

AI: Odkrywanie ukrytych struktur zaburzeń neurorozwojowych

Sztuczna inteligencja (AI) może zastosować szereg zaawansowanych strategii, aby przezwyciężyć złożoną i wieloaspektową heterogeniczność zaburzeń neurorozwojowych (NDD), takich jak zaburzenie ze spektrum autyzmu (ASD) czy zespół nadpobudliwości psychoruchowej z deficytem uwagi (ADHD) [1, 2].

Głównym celem tych strategii jest odejście od indukcyjnego procesu klasyfikacji objawów i wykorzystanie wielowymiarowych zbiorów danych w celu odkrycia ukrytych struktur biologicznych, które są bardziej precyzyjne i powiązane z rokowaniem i reakcją na leczenie [2-4].

Poniżej przedstawiono kluczowe strategie, które AI może wykorzystać w celu rozwiązania problemu złożonej heterogeniczności NDD:

1. Wykorzystanie zaawansowanych modeli uczenia maszynowego (ML)

AI wykorzystuje różne algorytmy uczenia maszynowego, aby przetwarzać dane i identyfikować wzorce, których nie można wykryć tradycyjnymi metodami statystycznymi [5, 6]:

- **Złożone klasyfikatory (np. Random Forest – RF):** Modele RF mogą osiągnąć bardzo wysoką dokładność klasyfikacji zaburzeń (np. 84% dla ADHD i 86% dla ASD) na podstawie cyfrowo zebranych danych, przewyższając prostsze podejścia, takie jak drzewa decyzyjne (DT) czy regresja logistyczna (LR) [7-9].
- **Interpretowalność i cechy predykcyjne:** Aby przezwyciężyć problem "czarnej skrzynki" w złożonych modelach (jak RF), można zastosować analizę SHAP (Shapley additive explanations), która ocenia wpływ poszczególnych zmiennych (np. płeć, ryzyko przed- i okołoporodowe, problemy rozwojowe) na wynik klasyfikacji [10-13].

2. Odkrywanie nowych struktur diagnostycznych (klastrowanie)

Heterogeniczność NDD oznacza, że istniejące kategorie diagnostyczne mogą nie odzwierciedlać prawdziwej struktury biologicznej [3, 14, 15].

- **Uczenie nienadzorowane (Unsupervised AI Algorithm):** Jest to podejście radykalne, które może zidentyfikować nowe, bardziej biologicznie znaczące kategorie diagnostyczne niezależne od istniejących konstruktów, takich jak ASD czy ADHD [3, 4, 6, 15]. Modele te mogą identyfikować **ukryte struktury** w danych, które lepiej korelują z endofenotypami, rokowaniem czy reakcją na leczenie [3].
- **Łączenie danych klinicznych i biologicznych:** Modele nienadzorowane mogą być wykorzystane do łączenia wielowymiarowych danych w celu identyfikacji endofenotypów, które są wspólne dla różnych zaburzeń neurorozwojowych, umożliwiając przypisanie jednostek do więcej niż jednej kategorii w sposób probabilistyczny [16].

3. Integracja danych wielowymiarowych i psycho-informatyka

AI może przezwyciężyć heterogeniczność, wykorzystując masywne i różnorodne zbiory danych (Big Data) [2, 17, 18].

- **Wielopoziomowa analiza biologiczna:** Kluczowym elementem jest integracja danych z różnych poziomów biologii:
  - **Genomika:** W celu rozwiązania patogenności wariantów o niepewnym znaczeniu (VUS) oraz przewidywania konsekwencji wariantów niekodujących [19, 20].
  - **Neuroobrazowanie i neurofizjologia:** AI może analizować dane, np. z fMRI i EEG, w celu poprawy interpretowalności sygnałów, które tradycyjnie miały zmienny sukces w identyfikacji biomarkerów [21, 22].
- **Analiza behawioralna w czasie rzeczywistym (Psycho-Informatyka):** Wykorzystanie danych z urządzeń wszechobecnej komputeryzacji (np. smartfonów, laptopów, czujników) do zbierania obiektywnych i drobnoziarnistych danych behawioralnych na temat interakcji użytkownika, co pozwala na uchwycenie stanu psychicznego i uniknięcie stronniczości samoopisów [23-27].

- **Przetwarzanie języka naturalnego (NLP):** NLP może analizować cyfrowe dokumenty zdrowotne i notatki kliniczne, przekształcając bogate, ale nieustrukturyzowane, dane tekstowe (zawierające unikalny wgląd ekspertów) w ustrukturyzowane dane kliniczne, które można powiązać ze znacznikami genetycznymi i fenotypami [15, 28].
- **Badania podłużne:** Algorytmy AI mogą śledzić i modelować progresję zaburzenia w czasie (zmienność wewnątrzosobniczą), co jest kluczowe, ponieważ NDD nie są statyczne [29].

4. Wsparcie kliniczne i etiopatogeneza

AI pomaga w lepszym zrozumieniu przyczyn i ukierunkowaniu interwencji:

- **Identyfikacja genetyki złożonej:** AI musi pomóc w określeniu **skali ryzyka poligenicznego** oraz **interakcji gen-gen**, które są prawdopodobnie dużym czynnikiem przyczyniającym się do wariancji fenotypowej NDD, ale są złożone obliczeniowo (problem NP-hard) [21, 30].
- **Wsparcie terapeutyczne i projektowanie leków:** AI jest kluczowe w przyspieszaniu badań nad lekami i ich projektowaniu, w tym w **repurposingu** istniejących leków poprzez identyfikację wspólnych ścieżek molekularnych u pacjentów (np. ścieżka mTOR) [31-33].
- **Triage i efektywność kliniczna:** ML, np. poprzez wykorzystanie drzew decyzyjnych (DT), może służyć do **sprawnego triażu pacjentów** [34-36] oraz automatyzacji wstępnych zadań diagnostycznych, takich jak zbieranie i wstępna analiza danych socjo-anamnestycznych [37-39]. Umożliwia to klinicystom przeznaczenie więcej czasu na złożone przypadki i indywidualizację terapii [37, 39, 40].

Wykorzystując te strategie, AI może przenieść diagnozę NDD z obecnego niejednoznacznego procesu na ścieżkę **medycyny precyzyjnej**, dostosowując interwencje do indywidualnych cech i biologii pacjenta [2, 4].