Zautomatyzowana analiza afektywna, synteza modeli multimodalnych i architektury Edge AI

Streszczenie

Dokument ten przedstawia kompleksową analizę dziedziny obliczeń afektywnych i zautomatyzowanej analizy twarzy (AFA), syntetyzując kluczowe postępy technologiczne, ramy teoretyczne, praktyczne zastosowania i implikacje etyczne w 2025 roku. Ekspresja twarzy, jako bogate źródło informacji o stanie emocjonalnym, intencjach i cechach demograficznych, stała się centralnym punktem zarówno dla nauk behawioralnych, jak i informatyki. Ewolucja tej dziedziny doprowadziła do powstania zaawansowanych systemów zdolnych do rozpoznawania, interpretowania i symulowania ludzkich emocji w czasie rzeczywistym.

Kluczowe wnioski obejmują przejście od prostych, kategorycznych modeli emocji (np. podstawowe emocje Ekmana) do bardziej złożonych modeli wymiarowych (walencja, pobudzenie) i deskryptywnych, które wykorzystują duże modele językowe (LLM) do generowania niuansowych opisów stanów afektywnych. Współczesne systemy opierają się na fuzji danych multimodalnych, łącząc analizę wizualną (ekspresje twarzy, mikromimika), wokalną (prozodia mowy) i tekstową, co znacząco przewyższa dokładność podejść jednomodalnych. Coraz większe znaczenie zyskują również obiektywne sygnały fizjologiczne, takie jak EEG, EKG i GSR, analizowane za pomocą hybrydowych architektur głębokiego uczenia, takich jak model CNN-BiLSTM-Transformer z mechanizmem uwagi, osiągający dokładność do 89,5% w benchmarkowych zbiorach danych.

Praktyczne wdrożenie tych systemów w czasie rzeczywistym jest możliwe dzięki architekturze Edge AI, która przenosi przetwarzanie danych na urządzenia brzegowe, minimalizując opóźnienia. Platformy takie jak Rockchip RK3588 i NVIDIA Jetson, wraz z narzędziami do kwantyzacji i optymalizacji modeli (np. RKNN Toolkit), umożliwiają działanie złożonych algorytmów na urządzeniach o ograniczonych zasobach. Zastosowania obejmują monitorowanie zdrowia psychicznego, zwiększanie bezpieczeństwa w motoryzacji, tworzenie adaptacyjnych gier wideo oraz rozwój robotyki społecznej. Równocześnie dynamiczny rozwój technologii spotkał się z reakcją regulacyjną, w szczególności w postaci Aktu o sztucznej inteligencji UE, który od 2025 roku wprowadza surowe zakazy stosowania systemów rozpoznawania emocji w miejscach pracy i instytucjach edukacyjnych, jednocześnie definiując wąskie wyjątki dla zastosowań medycznych i związanych z bezpieczeństwem.

Wprowadzenie do obliczeń afektywnych i analizy twarzy

Obliczenia afektywne, zdefiniowane jako interdyscyplinarna dziedzina zajmująca się systemami, które potrafią rozpoznawać, interpretować, przetwarzać i symulować ludzkie emocje, stanowią obecnie kluczowy element globalnej infrastruktury sztucznej inteligencji. Dziedzina ta, zapoczątkowana przez dr Rosalind Picard w MIT Media Lab pod koniec lat 90., ewoluowała od teoretycznych podstaw do fundamentalnego komponentu interakcji człowiek-komputer (HCI). Twarz ludzka od dawna jest przedmiotem zainteresowania naukowców, ponieważ przekazuje bogactwo informacji o wieku, płci, tożsamości, a także o uczuciach i myślach danej osoby. Reguluje interakcje międzyludzkie, komunikuje uczucia i dostarcza wglądu w procesy neurologiczne i psychologiczne.

Zainteresowanie informatyków analizą twarzy rozpoczęło się w latach 70. XX wieku, kiedy postrzegano ją jako potencjalny biometryczny identyfikator. W latach 90. skupiono się na wykorzystaniu wizji komputerowej do automatycznej analizy i syntezy ekspresji twarzy, co było możliwe dzięki opracowaniu w naukach behawioralnych szczegółowych systemów kodowania, takich jak Facial Action Coding System (FACS). Obecnie rynek technologii obliczeń afektywnych jest wyceniany na około 80,96 miliarda dolarów i przewiduje się, że do 2032 roku osiągnie wartość 375,56 miliarda dolarów, co świadczy o jego rosnącej integracji z sektorami takimi jak opieka zdrowotna, bezpieczeństwo motoryzacyjne i obsługa klienta.

Ramy teoretyczne i modele pomiaru emocji

Skuteczność systemów afektywnych zależy od zdolności do formalizowania ludzkich emocji w struktury, które maszyny mogą przetwarzać. W tym celu wykorzystuje się różne podejścia do pomiaru i klasyfikacji, zarówno oparte na obserwacji ludzkiej, jak i na modelach obliczeniowych.

Metody pomiaru oparte na obserwatorze ludzkim

Trzy główne podejścia do manualnego kodowania zachowań stanowią podstawę dla rozwoju zautomatyzowanych systemów:

1. **Pomiar oparty na komunikacie (Message-based):** Obserwatorzy dokonują inferencji na temat dyskretnych stanów emocjonalnych, takich jak "podstawowe emocje" zidentyfikowane przez Ekmana i innych (np. złość, smutek, strach, zdziwienie, wstręt). Podejście to zakłada, że twarz jest bezpośrednim "odczytem" emocji, co jest problematyczne, ponieważ znaczenie ekspresji jest silnie zależne od kontekstu. Ten sam wyraz twarzy może oznaczać triumf lub wściekłość, w zależności od sytuacji.

2. **Pomiar oparty na znaku (Sign-based):** Zamiast interpretować emocje, to podejście skupia się na czysto opisowej analizie obserwowalnych zmian na twarzy. Najbardziej

rozpowszechnioną metodą jest **Facial Action Coding System (FACS)**, który opisuje aktywność twarzy w kategoriach anatomicznie zdefiniowanych jednostek działania (Action Units, AU). System FACS, w zależności od wersji, definiuje od 33 do 44 jednostek AU, które mogą być kodowane binarnie (obecność/brak) lub na skali porządkowej (intensywność).

3. **Pomiar wymiarowy (Dimensional):** W przeciwieństwie do podejść kategorycznych, które podkreślają różnice między emocjami, pomiar wymiarowy koncentruje się na ich podobieństwach. Emocje są mapowane na ciągłych osiach, najczęściej **walencji** (przyjemność-nieprzyjemność) i **pobudzenia** (aktywacja-senność). Takie podejście pozwala na bardziej szczegółowe przedstawienie intensywności emocji i jest mniej podatne na błędy subiektywne, ponieważ oceny wielu niezależnych obserwatorów mogą być agregowane w celu uzyskania wysoce wiarygodnych miar.

Ewolucja w modelach obliczeniowych

Współczesne systemy afektywne często stosują podejście hybrydowe, wykorzystując metryki wymiarowe do śledzenia subtelnych zmian w intensywności emocji, a etykiety kategoryczne do raportowania zrozumiałego dla człowieka. Najnowszym trendem jest przejście w kierunku **deskryptywnego rozumienia emocji**. Wykorzystuje ono możliwości dużych modeli językowych (LLM) do generowania niuansowych, opisowych interpretacji stanów emocjonalnych, które wykraczają poza pojedyncze etykiety, np. "niespokojny, ale zdeterminowany".

Dodatkowo, zaawansowane modele uwzględniają złożoność czasową emocji, analizując dane w różnych oknach czasowych, aby odróżnić chwilowe reakcje od trwałych nastrojów.

Okno Czasowe	Czas trwania	Korelat Biologiczny/Poznawczy	Cel Obliczeniowy
Krótkoterminowe	0.5 – 2.0 s	Mikromimika, reakcja na zaskoczenie	Szybkie ruchy mięśni, skoki tonu
Średnioterminowe	2.0 – 10.0 s	Kontekstualne reakcje emocjonalne	Jednostki działania twarzy, zmiany prozodyczne
Długoterminowe	10.0 – 60.0 s+	Stany nastroju i regulacja emocjonalna	Zmiany bazowych sygnałów fizjologicznych, trendy nastroju

Zautomatyzowana analiza twarzy i systemy multimodalne

Zautomatyzowana analiza twarzy (AFA) ma na celu automatyczne wykrywanie i interpretowanie ekspresji przy użyciu algorytmów komputerowych. Proces ten jest złożony

i obejmuje kilka kluczowych etapów, a jego skuteczność znacznie wzrasta dzięki integracji z innymi modalnościami danych.

Potok przetwarzania w systemach AFA

Typowy system AFA działa według następującego schematu:

1. **Wykrywanie i śledzenie twarzy:** Lokalizacja twarzy w obrazie lub klatce wideo (np. przy użyciu detektora Violi-Jonesa), a następnie śledzenie kluczowych punktów (np. kącików oczu, ust) za pomocą technik takich jak Aktywne Modele Wyglądu (AAM) lub Ograniczone Modele Lokalne (CLM).

2. **Rejestracja:** Normalizacja obrazu twarzy do kanonicznego rozmiaru i orientacji w celu usunięcia zmienności wynikającej z pozycji i rotacji głowy.

3. **Ekstrakcja cech:** Wydobycie informacji opisujących ekspresję. Cechy te dzielą się na trzy główne kategorie:

    - **Geometryczne:** Oparte na lokalizacji i przemieszczeniach punktów charakterystycznych na twarzy (np. brwi, oczy).

    - **Wyglądu (Appearance):** Reprezentują zmiany w teksturze skóry, takie jak zmarszczki, bruzdy i fałdy. Do ich opisu wykorzystuje się techniki takie jak sploty Gabora, HOG czy SIFT.

    - **Ruchu:** Opisują dynamikę ekspresji, wykorzystując np. przepływ optyczny lub obrazy historii ruchu (MHI).

4. **Uczenie maszynowe:** Klasyfikacja lub regresja na podstawie wyekstrahowanych cech. Wczesne systemy wykorzystywały sieci neuronowe, podczas gdy nowsze opierają się na maszynach wektorów nośnych (SVM) do klasyfikacji statycznej oraz na ukrytych modelach Markowa (HMM) i dynamicznych sieciach bayesowskich do modelowania czasowego.

Fuzja multimodalna: trzy filary percepcji

Badania jednoznacznie wskazują, że systemy multimodalne, integrujące różne źródła danych, osiągają znacznie wyższą dokładność niż te oparte tylko na jednej modalności. W 2025 roku standardem jest fuzja trzech głównych filarów:

1. **Analiza Tekstualna (TER):** Wykorzystuje sieci neuronowe (RNN, LSTM) do analizy semantycznej i kontekstowej tekstu, co jest kluczowe dla wykrywania sarkazmu i emocji niejawnych.
2. **Analiza Akustyczna:** Koncentruje się na cechach paralingwistycznych mowy (ton, głośność, rytm). Nowoczesne modele językowo-mówione (SLM), takie jak EVI 3 firmy Hume AI, przetwarzają sygnał akustyczny i treść językową w jednym, zunifikowanym modelu, co pozwala na analizę interakcji między słowami a sposobem ich wypowiadania.
3. **Analiza Wizualna:** Używa splotowych sieci neuronowych (CNN) do mapowania punktów charakterystycznych twarzy i monitorowania grup mięśni. Zaawansowane modele potrafią wykrywać mikromimikę – mimowolne, ułamki sekundy trwające ruchy twarzy, które ujawniają prawdziwe emocje.

Sygnały fizjologiczne: bezpośrednie okno na emocje

Integracja sygnałów fizjologicznych oferuje obiektywny wgląd w stany afektywne, ponieważ są one mniej podatne na świadomą manipulację. Najczęściej wykorzystywane sygnały to:

- **Elektroencefalografia (EEG):** Monitoruje aktywność mózgu, dostarczając informacji o stanach poznawczych, takich jak skupienie, frustracja i zaangażowanie.
- **Reakcja skórno-galwaniczna (GSR):** Mierzy przewodnictwo skóry, które wzrasta wraz z aktywnością gruczołów potowych, co jest wiarygodnym wskaźnikiem pobudzenia emocjonalnego.
- **Fotopletyzmografia (PPG) / Elektrokardiografia (EKG):** Śledzi zmienność rytmu serca, co pozwala na ocenę poziomu stresu.

Zaawansowane architektury głębokiego uczenia

Postęp w dziedzinie obliczeń afektywnych jest nierozerwalnie związany z rozwojem zaawansowanych architektur głębokiego uczenia, zdolnych do przetwarzania złożonych, multimodalnych i czasowych danych.

Model CNN-BiLSTM-Transformer z mechanizmem uwagi

Jedną z dominujących architektur w 2025 roku jest hybrydowy model łączący zalety kilku sieci neuronowych w celu kompleksowej analizy sygnałów fizjologicznych:

- **Splotowe Sieci Neuronowe (CNN):** Służą do ekstrakcji cech przestrzennych z surowych sygnałów (np. map elektrod EEG).
- **Dwukierunkowe Sieci LSTM (BiLSTM):** Modelują zależności czasowe, przetwarzając dane sekwencyjne zarówno w przód, jak i w tył, co pozwala na uwzględnienie kontekstu przeszłego i przyszłego.
- **Koder Transformer:** Wykorzystuje mechanizm samo-uwagi (self-attention) do wychwytywania długodystansowych zależności w danych szeregów czasowych, co jest kluczowe dla zrozumienia zmian emocjonalnych w dłuższych okresach.
- **Fuzja oparta na uwadze (Attention-based Fusion):** Zamiast prostej konkatenacji cech z różnych modalności, mechanizm uwagi dynamicznie przypisuje wagi do poszczególnych sygnałów (np. EEG, EKG, GSR, EMG) w zależności od ich istotności dla danego zadania klasyfikacyjnego.

Podejście to zostało zwalidowane na publicznie dostępnych zbiorach danych, takich jak **DEAP** i **AMIGOS**, osiągając dokładność klasyfikacji odpowiednio **88,2%** i **89,5%**. Wyniki te znacząco przewyższają tradycyjne metody uczenia maszynowego (SVM, Random Forest) oraz prostsze modele głębokiego uczenia (np. CNN-LSTM).

Zwrot Generatywny i Duże Modele Językowe (LLM)

Najbardziej transformacyjnym postępem jest integracja multimodalnych dużych modeli językowych (MLLM), która zmienia paradygmat z zadań dyskryminacyjnych (przypisywanie etykiet) na **złożone rozumienie emocji** (generowanie wyjaśnień).

- **AffectGPT:** Jest to czołowy model w tym paradygmacie, który integruje cechy audio i wideo z danymi tekstowymi na wczesnym etapie przetwarzania, umożliwiając modelowi rozumowanie na temat sygnałów niewerbalnych w ramach jego silnika językowego.
- **Hume AI EVI 3:** Stanowi kamień milowy w empatycznej interakcji w czasie rzeczywistym. Jest to model mowa-do-mowy, który potrafi odpowiadać z naturalną, ekspresyjną mową w czasie krótszym niż 300 ms. Jego styl mówienia i osobowość mogą być kontrolowane za pomocą prostych instrukcji tekstowych.

Infrastruktura dla czasu rzeczywistego: Edge AI

Wdrożenie systemów afektywnych w aplikacjach wymagających natychmiastowej reakcji, takich jak autonomiczne pojazdy czy robotyka, jest uzależnione od minimalizacji opóźnień.

Odpowiedzią na to wyzwanie jest **Edge AI**, czyli przetwarzanie danych bezpośrednio na urządzeniu końcowym.

Wymagania i Sprzęt dla Edge AI

Lokalizacja przetwarzania	Docelowe opóźnienie	Przykładowe zastosowanie	Przykład sprzętu
U źródła (Edge)	1 – 10 ms	Pojazdy autonomiczne, Robotyka	NVIDIA Jetson Orin, Rockchip RK3588
Lokalny hub (Fog)	10 – 100 ms	Inteligentny dom, Fabryka przemysłowa	Bramy brzegowe (Edge Gateways)
Zdalnie (Chmura)	100 ms – 2 s+	Długoterminowa analityka nastroju	Scentralizowane centra danych

Aby sprostać tym wymaganiom, modele muszą być optymalizowane za pomocą technik takich jak kwantyzacja. Platformy sprzętowe, jak **Khadas Edge2** z procesorem **Rockchip RK3588**, oferują dedykowane jednostki przetwarzania neuronowego (NPU) z natywnym wsparciem dla modeli o niższej precyzji (INT8, FP16) oraz niskim zużyciem energii (5-10 W), co czyni je idealnym rozwiązaniem dla zastosowań brzegowych.

Oprogramowanie i narzędzia

Wdrożenie na urządzeniach brzegowych jest wspierane przez specjalistyczne zestawy narzędzi:

- **RKNN Toolkit:** Umożliwia konwersję modeli z popularnych frameworków (PyTorch, TensorFlow) do formatu działającego natywnie na NPU Rockchip.
- **RKNN Model Zoo:** Zbiór wstępnie wytrenowanych modeli zoptymalizowanych pod kątem platformy Rockchip.
- **NVIDIA DeepStream / Intel OpenVINO:** Dominujące frameworki do tworzenia potoków przetwarzania w czasie rzeczywistym, które integrują wiele strumieni danych (wideo, audio) z algorytmami AI.

Zastosowania i wpływ społeczny

Technologie afektywne znajdują coraz szersze zastosowanie w różnych dziedzinach, wpływając na interakcje międzyludzkie i sposób funkcjonowania systemów.

- **Opieka zdrowotna:** Monitorowanie zdrowia psychicznego (np. chatbot Woebot, który redukuje objawy lęku o 35% w ciągu czterech tygodni), wykrywanie bólu fizycznego, wczesne ostrzeganie przed epizodami depresyjnymi.
- **Bezpieczeństwo motoryzacyjne:** Systemy w pojazdach monitorują kierowców pod kątem zmęczenia, stresu i rozproszenia uwagi, wykorzystując zarówno sygnały wizualne, jak i fizjologiczne.
- **Gry i media interaktywne:** Algorytmy AI dostosowują poziom trudności gry w czasie rzeczywistym w oparciu o reakcje emocjonalne gracza, a postacie niezależne (NPC) prowadzą bardziej realistyczne dialogi.
- **Robotyka społeczna:** Roboty takie jak Ameca i Sophia są wyposażone w zdolności afektywne, aby funkcjonować w rolach opiekuńczych i obsłudze klienta, ucząc się nowych wskazówek społecznych przez obserwację.
-

Globalne zarządzanie etyczne: Akt o AI UE

Szybka ekspansja obliczeń afektywnych wywołała znaczące reakcje regulacyjne, z których najważniejszą jest **Akt o sztucznej inteligencji UE**, który wszedł w pełni w życie na przełomie 2024 i 2025 roku.

Zakazy w Miejscach Pracy i Instytucjach Edukacyjnych

Od 2 lutego 2025 roku Artykuł 5(1)(f) Aktu o AI **zakazuje** używania systemów AI do wnioskowania o emocjach osób fizycznych w następujących kontekstach:

- **Miejsce pracy:** Obejmuje to zarówno rekrutację (zapobieganie stronniczości), jak i monitorowanie wydajności pracowników (np. poziomu stresu czy zaangażowania).
- **Instytucje edukacyjne:** Zakazane jest stosowanie systemów monitorujących zainteresowanie lub uwagę uczniów w klasach i na platformach e-learningowych.

Naruszenia tych zakazów mogą skutkować karami w wysokości do 35 milionów euro lub siedmiu procent globalnego rocznego obrotu firmy.

Dozwolone zastosowania i wyjątki

Akt przewiduje wąskie wyjątki, w których rozpoznawanie emocji jest dozwolone ze względów **medycznych lub bezpieczeństwa**:

- **Narzędzia diagnostyki medycznej:** Systemy używane w warunkach klinicznych do celów terapeutycznych są wyłączone spod zakazu.
- **Infrastruktura krytyczna dla bezpieczeństwa:** Dozwolone jest stosowanie AI do wykrywania zmęczenia pilotów lub rozproszenia kierowców w transporcie komercyjnym.
- **Marketing komercyjny:** Chatboty wykrywające emocje klientów w handlu detalicznym są generalnie dozwolone, pod warunkiem zgodności z wymogami przejrzystości i ochrony danych.

Perspektywy na Przyszłość (2025–2034)

W nadchodzącej dekadzie oczekuje się dalszego rozwoju obliczeń afektywnych w kilku kluczowych obszarach:

- **Neuro-symboliczna AI:** Integracja rozumowania symbolicznego z modelami neuronowymi w celu poprawy długoterminowego rozumienia kontekstu emocjonalnego użytkownika.
- **Ubezpieczenie od halucynacji:** W miarę centralizacji generatywnej AI afektywnej, mogą pojawić się oferty ubezpieczeniowe chroniące przed szkodami wynikającymi z nieprawidłowych ocen emocjonalnych przez AI.
- **Systemy samodoskonalące:** W przypadku pojawienia się ogólnej sztucznej inteligencji (AGI), systemy afektywne mogą uzyskać zdolność do autonomicznego generowania i udoskonalania własnych danych treningowych, co pozwoliłoby im adaptować się do kulturowych zmian w ekspresji emocjonalnej bez interwencji człowieka.